

Percepção do risco em ambiente rodoviário urbano

Pedro Miguel Sousa Vieira

Tese para obtenção do grau de mestre em
Engenharia Electrotécnica e de Computadores

Orientadores: Doutor Manuel Ricardo de Almeida Rodrigues Marques

Prof. João Paulo Salgado Arriscado Costeira

Júri

Presidente: Prof. João Fernando Cardoso Silva Sequeira

Orientador: Doutor Manuel Ricardo de Almeida Rodrigues Marques

Vogais: Prof. Filipe Manuel Mercier Vilaça e Moura

Doutor Carlos Miguel Lima de Azevedo

Novembro 2015

Agradecimentos

Quero agradecer aos meus dois orientadores Doutor Manuel Marques e Professor João Paulo Costeira, pela orientação e todo o tempo dedicado no desenrolar desta tese.

À minha namorada Ana Carreiro, aluna finalista de Cardiopneumologia, pela sua ajuda no esclarecimento da resposta cardíaca em situações de *stress*, nomeadamente a influência dos sistemas simpático e parassimpático na variabilidade cardíaca.

Deixo ainda o meu agradecimento à minha família, que mesmo estando longe sempre me apoiaram nos momentos mais difíceis e me permitiram a conclusão deste curso.

Resumo

Dado a condicionantes económicas, ecológicas e sociais, a bicicleta tem assumido cada vez mais expressão como meio de transporte urbano. De facto, o número de ciclistas nas estradas das cidades tem vindo a aumentar nos últimos anos.

Nesta dissertação desenvolveu-se uma aplicação e um método exemplificativo de como os *smartphones* podem ser utilizados no estudo desta crescente actividade. Dotados de vários sensores, receptores GPS e de boas câmaras, tornam-se dispositivos ideais devido ao seu poder e abundância.

Palavras-chave

Ciclista, HRV, *Optical-flow*, *Smartphone*, Stress, Trânsito.

Abstract

Given ecological and socioeconomic aspects, the bicycle is slowly becoming the main way of transportation to a lot of people. In fact, the number of cyclists in the city streets has been increasing in the past few years.

In this master thesis a smartphone app and a method was developed to study the urban cyclists. It shows how today smartphones can be used to study this increasing activity. Due to the fact that these devices are equipped with several sensors, such as gyroscopes, accelerometers, GPS receivers and good cameras, they become the perfect candidates for this job

Palavras-chave

Cyclist, HRV, Optical-flow, Smartphone, Stress, Traffic.

Índice

Agradecimentos	ii
Resumo	iv
Abstract.....	v
Índice	vi
Lista de Figuras	viii
Lista de Acrónimos.....	x
Lista de Símbolos.....	xi
Lista de Software	xii
1 Introdução	1
1.1 A bicicleta na cidade moderna.....	2
1.2 Estado da arte	2
1.3 Organização de Conteúdos	3
1.4 Contribuições.....	5
2 Descrição dos Componentes	6
2.1 Descrição do Sistema de Aquisição	7
2.2 Smartphone	8
2.2.1 Aplicação - <i>Bike Monitor</i>	9
2.3 Action Cam.....	11
2.4 Cinta cardíaca	13
3 Processamento dos Sinais e Detecção de Eventos	14
3.1 Processamento de imagem.....	15
3.1.1 Cálculo do <i>Optical Flow</i>	16
3.1.2 Filtragem do <i>Optical Flow</i>	18
3.1.3 Descritor da imagem	21
3.1.4 Classificador de eventos	24
3.1.5 Detecção de obstáculos na berma	28
3.2 Detecção de irregularidades na via usando o acelerómetro.....	30
3.3 Processamento do ECG	32

3.3.1	Funcionamento básico do ciclo cardíaco	32
3.3.2	Cálculo do HRV	33
4	Análise do Sistema Experimental em Ambiente Real.....	37
4.1	Factores potenciadores de <i>stress</i>	39
4.1.1	Velocidade do ciclista	39
4.1.2	Proximidade de obstáculos na berma	40
4.1.3	Ciclista a ser ultrapassado pela esquerda	42
4.1.4	Irregularidades na via	44
4.2	HRV - Variabilidade cardíaca	46
5	Conclusões	49
5.1	Conclusões.....	50
5.2	Trabalho futuro	50
	Referências.....	51

Lista de Figuras

<i>Figura 1.3.1 – Arquitectura do sistema desenvolvido.</i>	4
<i>Figura 2.1.1 – Esquema dos componentes do sistema.</i>	7
<i>Figura 2.2.1 – Smartphone montado na bicicleta.</i>	8
<i>Figura 2.2.2 – Suporte adaptado usado para segurar o Smartphone ao guiador.</i>	8
<i>Figura 2.2.3 – Homescreen da App.</i>	9
<i>Figura 2.2.4 – Fluxograma do funcionamento da App Bike Monitor.</i>	10
<i>Figura 2.2.5 – Samsung Galaxy SII correndo a App desenvolvida.</i>	10
<i>Figura 2.3.1 – Action Cam montada no quadro da bicicleta.</i>	11
<i>Figura 2.3.2 – Esquema da Action Cam montada no guiador.</i>	11
<i>Figura 2.3.3 – Esquema da Action Cam montada no quadro.</i>	12
<i>Figura 2.3.4 – Action Cam Qumox SJ4000.</i>	12
<i>Figura 2.4.1 – Cinta cardíaca colocada no peito do ciclista.</i>	13
<i>Figura 3.1.1 – Fluxograma do processamento de imagem.</i>	15
<i>Figura 3.1.2 – Vector de movimento numa sequência de imagens.</i>	16
<i>Figura 3.1.3 – Imagem com a zona de análise demarcada a amarelo.</i>	17
<i>Figura 3.1.4 – Dimensões e localização da janela de pontos face ao tamanho da imagem.</i>	17
<i>Figura 3.1.5 – Esquema do cálculo tradicional do optical flow entre duas imagens.</i>	18
<i>Figura 3.1.6 – Esquema adoptado para o cálculo do optical flow entre três imagens.</i>	18
<i>Figura 3.1.7 – Vectores com ângulos muito distintos pelo que são considerados como outliers.</i>	19
<i>Figura 3.1.8 – Vectores considerados como inliers pelo método.</i>	19
<i>Figura 3.1.9 – Optical flow resultante do método tradicional entre duas imagens.</i>	20
<i>Figura 3.1.10 – Optical flow resultante do método adoptado entre três imagens.</i>	20
<i>Figura 3.1.11 – Círculo trigonométrico com a discretização dos vectores do optical flow.</i>	21
<i>Figura 3.1.12 – Divisão da janela de análise do optical flow.</i>	22
<i>Figura 3.1.13 – Histogramas da direcção dos vectores de cada rectângulo de análise.</i>	22
<i>Figura 3.1.14 – Norma média dos vectores em cada rectângulo.</i>	23
<i>Figura 3.1.15 – Exemplo de imagem e histogramas do ciclista a virar à direita.</i>	24
<i>Figura 3.1.16 – Exemplo de imagem e histogramas de ciclista a virar à esquerda.</i>	25
<i>Figura 3.1.17 – Exemplo de imagem e histogramas de ciclista a ser ultrapassado pela esquerda.</i>	25
<i>Figura 3.1.18 – Imagem e norma média dos vectores numa situação bem classificada de “ciclista parado”.</i>	26
<i>Figura 3.1.19 – Imagem e norma média dos vectores, ciclista está parado mas há muito movimento à sua frente, levando a uma classificação errada do evento.</i>	26
<i>Figura 3.1.20 – Matriz confusão construída a partir das imagens classificadas.</i>	27
<i>Figura 3.1.21 – Número médio de imagens classificadas correctamente no top 10 em cada classe.</i>	27
<i>Figura 3.1.22 – Janela de análise com marcação do rectângulo usado no cálculo da proximidade da berma</i>	28

<i>Figura 3.1.23 – Obstrução de bermas: imagem A - Berma desobstruída, imagem B - Berma com obstrução.....</i>	29
<i>Figura 3.2.1 – Referencial ao sistema bicicleta</i>	30
<i>Figura 3.2.2 – Esquema da detecção de irregularidade na via.</i>	31
<i>Figura 3.2.3 – Buraco na via detectado pelo sistema desenvolvido.....</i>	31
<i>Figura 3.3.1 – Intervalos RR representados num ECG.</i>	33
<i>Figura 3.3.2 – PSD dos intervalos RR.....</i>	34
<i>Figura 3.3.3 – PSD com o domínio da estimulação parassimpática.....</i>	35
<i>Figura 3.3.4 – PSD com domínio da estimulação simpática.....</i>	35
<i>Figura 3.3.1 – Mapa do percurso exemplo em análise</i>	38
<i>Figura 4.1.1 – Mapa da velocidade ao longo do percurso.</i>	39
<i>Figura 4.1.2 – Razão da proximidade da berma.</i>	40
<i>Figura 4.1.3 – Situação A – Berma obstruída. Situação B – Ciclista num cruzamento, berma desobstruída.....</i>	41
<i>Figura 4.1.4 – Distribuição do evento “Ultrapassado pela esquerda” ao longo do percurso.</i>	42
<i>Figura 4.1.5 – Ponto O - Evento bem detectado. Ponto X – Falso positivo</i>	43
<i>Figura 4.1.6 – Imagens do ponto O e ponto X.....</i>	43
<i>Figura 4.1.7 – Mapa com a georreferenciação das irregularidades da via.....</i>	44
<i>Figura 4.1.8 – Irregularidade na via detectada por ambos os métodos: desnível na estrada devido a remoção do alcatrão.</i>	45
<i>Figura 4.1.9 – Falso positivo do evento “irregularidade da via”, detectado pelo sensor óptico.</i>	45
<i>Figura 4.2.1 – Distribuição geográfica do ratio LF/HF.</i>	46
<i>Figura 4.2.2 – Mapa do ratio LF/HF com subida assinalada.....</i>	47
<i>Figura 4.2.3 – Mapa do ratio LF/HF com zonas assinalados.....</i>	47
<i>Figura 4.2.4 – Ultrapassagem rasante ao ciclista pela esquerda.</i>	48
<i>Figura 4.2.5 – Imagem da zona B - Rotunda do Areeiro.</i>	48

Lista de Acrónimos

APP	Application
ECG	Electrocardiograma
EEG	Electroencefalografía
FFT	Fast Fourier Transform
FPS	Frames per second
GPS	Global Positioning System
HF	High Frequency
HRV	Heart Rate Variability
LF	Low Frequency
MIT	Massachusetts Institute of Technology
PSD	Power Spectral Density

Lista de Símbolos

RR

VO2

Intervalo entre batimentos cardíacos

Consumo de oxigénio

Lista de Software

Android Studio	Ambiente de desenvolvimento integrado para aplicações Android
Gimp	Software de edição de imagem
Mathworks Matlab r2012b	Software interactivo de cálculo numérico
Google Maps	Serviço de pesquisa e visualização de mapas
Microsoft Word 2010	Processador de texto
OpenCV	Biblioteca de processamento de visão computacional

Capítulo 1

Introdução

Este capítulo pretende dar uma visão geral do problema em análise, bem como as soluções já existentes para o problema. Apresenta também a organização do trabalho e as contribuições deste para projectos futuros.

1.1 A bicicleta na cidade moderna

O número de bicicletas está a aumentar na europa, sendo vendidas 2 bicicletas por cada carro vendido. No ano de 2011 foram vendidas na União Europeia cerca de 20 milhões de bicicletas [1].

A utilização da bicicleta como meio de transporte está a aumentar na cidade de Lisboa. Este aumento, porém, também trouxe consigo um maior número de acidentes [2].

No ano de 2013 a PSP registou 915 ocorrências com velocípedes, sendo que este número tendia a aumentar até à data de 31 de Maio de 2014 [2]. Com este aumento, sentiu-se a necessidade de caracterizar a causa destes acidentes, mas em concreto verificar as condições de *stress* a que os ciclistas urbanos são submetidos, mapeando ruas, cruzamentos, rotundas, outras vias e zonas da cidade a nível de *stress*.

Para acomodar este maior número de ciclistas as cidades têm de se adaptar, construindo ciclovias, reservando faixas a ciclistas. É possível determinar que zonas e vias necessitam de intervenção, através do estudo da percepção de risco dos ciclistas, sendo que o *stress* é um indicador da percepção de risco.

Este trabalho vem ao encontro desta necessidade, pois visa desenvolver uma ferramenta para o estudo das condições dos ciclistas em ambiente urbano. Para tal equipou-se um ciclista com um *smartphone*, uma câmara e uma cinta cardíaca que recolhem diversos dados. Estes dados, depois de processados, conseguem mapear aspectos e zonas críticas da cidade que necessitam de melhoramentos.

1.2 Estado da arte

Não existem muitos estudos nesta área, sendo que estudos anteriormente feitos na caracterização de vias em termos de conforto para os ciclistas baseavam-se em inquéritos e cálculos empíricos [3]. Estes permitem caracterizar as vias de maior desconforto para os ciclistas, através de cálculos envolvendo várias variáveis tais como: larguras das estradas, afluência de tráfego, limites de velocidade, existência ou não de via reservada a ciclistas, entre outras [4].

Ao contrário destes estudos empíricos, recentemente um trabalho realizado no MIT utiliza dados de um capacete com um sensor EEG. Este é capaz de monitorizar as ondas cerebrais, mapeando com maior precisão as zonas de maior *stress* [5].

Muito recentemente iniciou-se alguns projectos de recolha de dados de ciclistas utilizando *smartphones*. Na *International Cycling Safety Conference 2014*, foi apresentada uma aplicação para *smartphones* capaz de detectar acidentes de um ciclista. A aplicação, ao detectar o acidente, envia uma mensagem de emergência com o local georreferenciado por GPS aos serviços de emergência

[6]. Outra aplicação surgiu na cidade de Toronto, a *Toronto Cycling App*, é uma aplicação que recolhe os dados GPS dos ciclistas. Estes dados recolhidos serão analisados e usados para o planeamento de infra-estruturas para ciclistas, tal como a criação de vias clicáveis [7].

Com este trabalho pretende-se desenvolver um método de estudo económico, de fácil implementação em larga escala. Para tal criou-se um método que, além de recolher dados GPS, também consegue analisar a qualidade do piso, o estado de *stress* do ciclista e analisar a envolvente deste através de uma câmara. Pretende-se que este método extraia dados relevantes para o planeamento das vias clicáveis nas cidades, tais como estado do piso das vias, níveis de tráfego nas faixas onde circulam os ciclistas e mapas de *stress* das vias [8].

1.3 Organização de Conteúdos

Neste trabalho desenvolveu-se um método de estudo sobre o estado de *stress* dos ciclistas urbanos. Para o efeito recorreu-se a um *smartphone*, equipamento que hoje se encontra na pose da maioria da população e que vem apetrechado de uma larga variedade de sensores: câmaras, acelerómetros, giroscópios, GPS.

Através da análise da imagem, pretende-se identificar eventos típicos que ocorrem durante um percurso citadino de bicicleta, que podem causar *stress* para o ciclista. Com base nesta informação, mostrou-se que é possível fazer um mapeamento entre estas situações e potenciais estados de *stress*.

Este trabalho comporta três instantes distintos: a aquisição de dados em *real-time*, o processamento destes dados num PC *offline* e os dados resultantes deste processamento (figura 1.3.1).

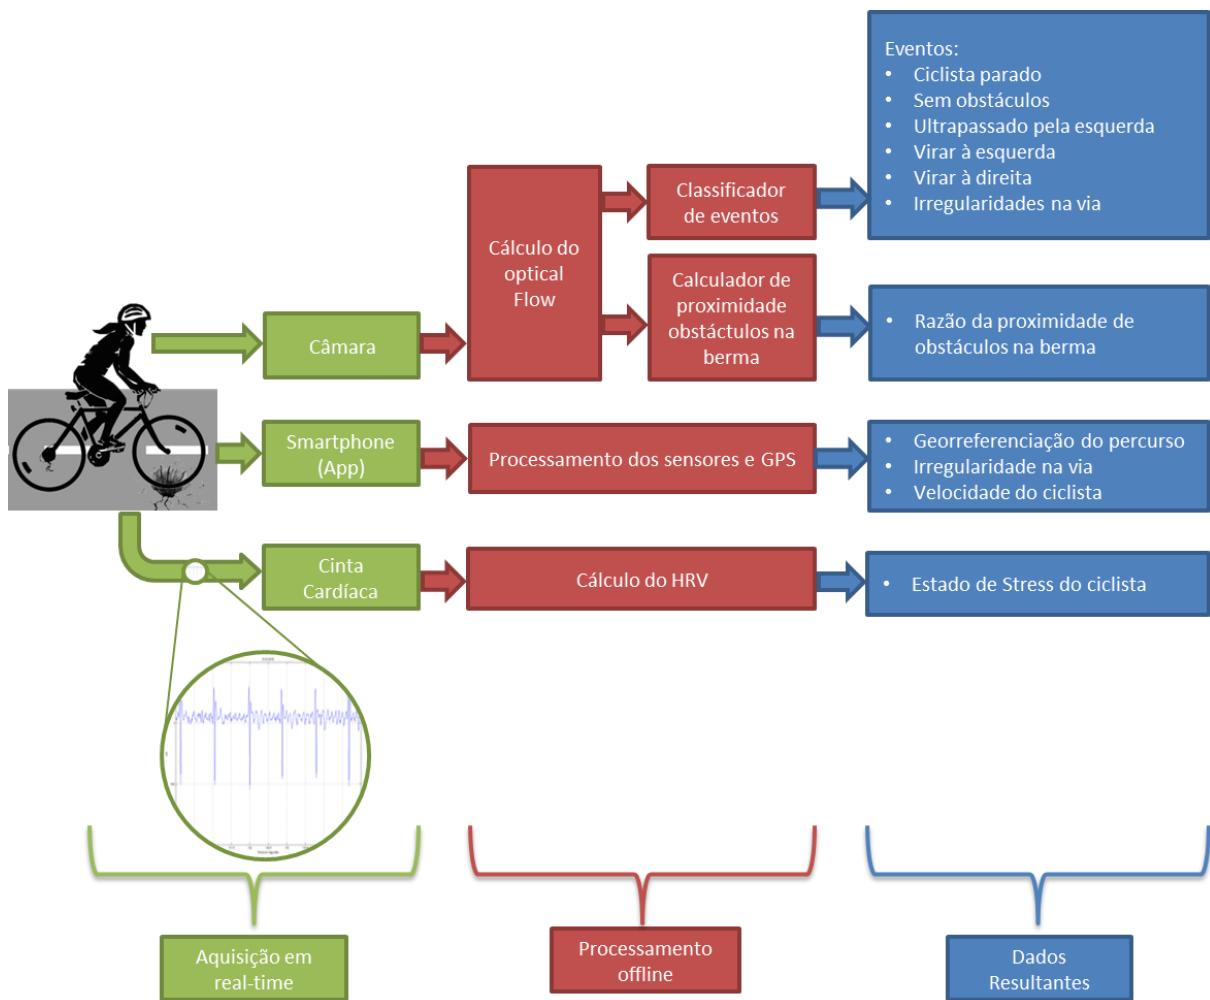


Figura 1.3.1 – Arquitectura do sistema desenvolvido.

A aquisição de dados é feita através de uma câmara, de uma cinta cardíaca e de um *smartphone* munido da App desenvolvida neste trabalho.

Esta dissertação está dividida em 5 capítulos, incluindo este primeiro capítulo introdutório.

No capítulo 2 apresenta-se o funcionamento básico do sistema e cada um dos seus 3 constituintes: o *smartphone*, a *action cam* e a cinta cardíaca.

No 3º capítulo inclui-se todo o processamento e métodos aplicados aos dados recolhidos dos três constituintes do sistema e que variáveis foram consideradas neste trabalho.

O capítulo 4 apresenta o comportamento do sistema desenvolvido em ambiente real, onde se pode observar a distribuição geográfica das diversas variáveis em estudo.

Por fim, o capítulo 5 centra-se nas conclusões e no trabalho a desenvolver no seguimento desta tese.

1.4 Contribuições

Com este trabalho desenvolveu-se e disponibilizou-se uma *App Android* que pode ser usada para recolha contínua de vídeo e dos dados dos sensores de um *smartphone*. Esta pode ser usada na análise da circulação dos ciclistas, mas também poderá ser usada noutras actividades em estudos futuros.

No decorrer deste trabalho, foram feitos vários percursos de bicicleta em ambiente urbano, sendo que foi construída uma base de dados onde estão disponibilizados todos os dados destes percursos. Foram recolhidas cerca de 2h00 de dados que correspondem a um total de 10 percursos, 8 deles na cidade de Lisboa e 2 deles na cidade de Ponta Delgada. Estes percursos possuem os seguintes dados devidamente sincronizados:

- Georreferenciação GPS;
- Vídeo;
- Registo electrocardiográfico (ECG);
- Aceleração nos 3 eixos (Acelerómetro), e
- Rotação nos 3 eixos (Giroscópio).

Também foi disponibilizado o software de análise para estes dados.

Capítulo 2

Descrição dos Componentes

Este capítulo foca-se na explicação dos constituintes do sistema de aquisição de dados e a forma como foram montados e agrupados num sistema.

Nesta tese pretende-se criar um sistema baseado num *smartphone*, de modo a permitir a sua fácil implementação e replicação em larga escala. No entanto, o modelo do *smartphone* e o suporte de fixação utilizados neste trabalho não eram os mais indicados por razões que são abordadas no desenvolver deste capítulo. Assim, optou-se por utilizar uma câmara externa para a aquisição de imagens em detrimento da câmara do *smartphone*.

2.1 Descrição do Sistema de Aquisição

Foi definido o sistema “ciclista-bicicleta”, onde se utilizaram três componentes: uma *Action Cam* que adquire imagens de modo a identificar obstáculos e eventuais causas de *stress* no ciclista, uma cinta cardíaca que permite o registo electrocardiográfico e *um smartphone* montado no guiador da bicicleta que adquire a posição GPS e os dados dos acelerómetros.

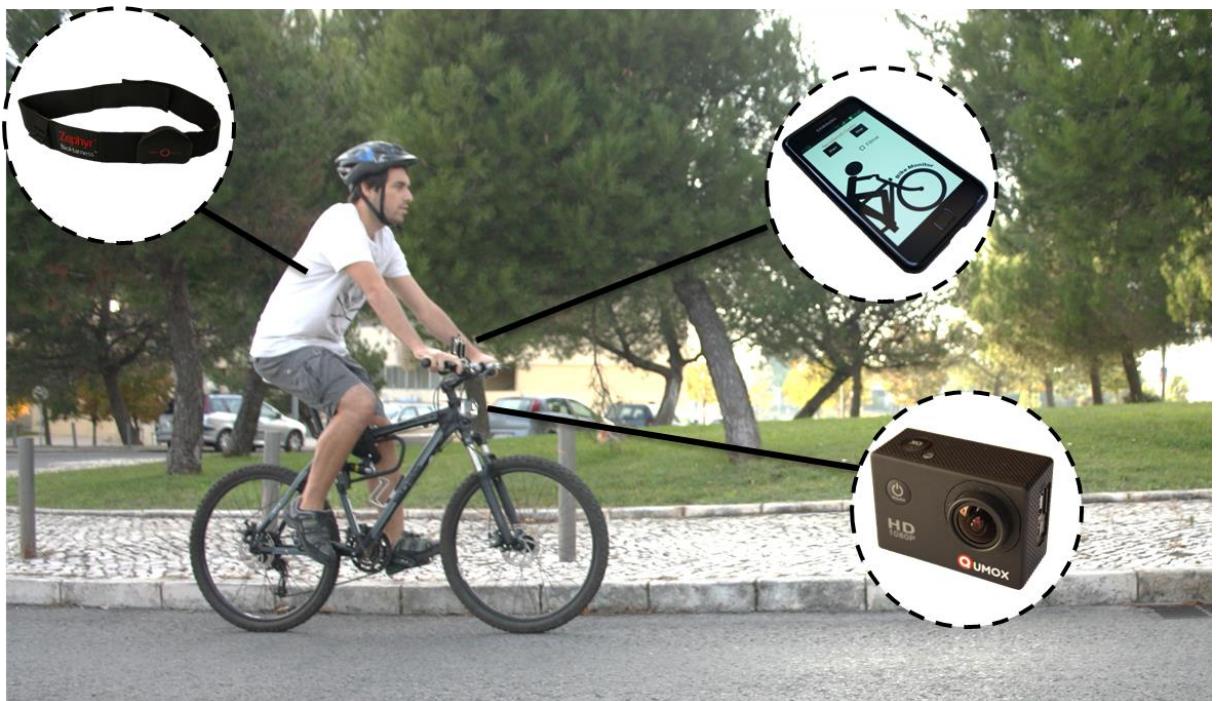


Figura 2.1.1 – Esquema dos componentes do sistema.

Os relógios internos dos três equipamentos foram sincronizados de modo a poderem operar de forma independente, sendo então possível a posterior sincronização e análise dos dados.

2.2 Smartphone

O *Smartphone*, por ser um aparelho barato e abundante nos dias de hoje, foi escolhido para registar tanto as coordenadas GPS como as acelerações através dos seus acelerómetros.



Figura 2.2.1 – Smartphone montado na bicicleta.

O *smartphone* foi montado no guiador da bicicleta através de um suporte adaptado de um *Selfie Stick* com um suporte de *Action Cam* (Figura 2.2.2).



Figura 2.2.2 – Suporte adaptado usado para segurar o Smartphone ao guiador.

2.2.1 Aplicação - *Bike Monitor*

Para o registo da localização GPS e dos valores dos sensores, foi desenvolvida uma App para a plataforma *Android*, denominada “*Bike Monitor*”. Esta App tem apenas a função de recolha de dados, sendo que a sua utilização é muito simples.



Figura 2.2.3 – *Homescreen* da App.

São recolhidos os seguintes dados:

- Coordenadas geográficas (GPS)
- Acelerações nos 3 eixos (Acelerómetro)
- Rotação (Giroscópio)
- Imagem (Câmara): a opção “Filmar” é opcional e é apenas aconselhada caso o suporte do telemóvel seja muito estável e não oscile e caso a qualidade da câmara do aparelho seja boa, de modo a que as imagens não apresentem o efeito de *Rolling Shutter*. A resolução e o framerate do vídeo podem ser ajustados pelo utilizador.

Ao premir o botão “*Start*”, a aplicação inicia a recolha dos dados acima mencionados, guardando-os ciclicamente num ficheiro .txt com a respectiva data e hora de aquisição, de modo a ser possível sincronizar com os dados da cinta cardíaca e da *Action Cam*. No fluxograma abaixo pode-se verificar o funcionamento da mesma.

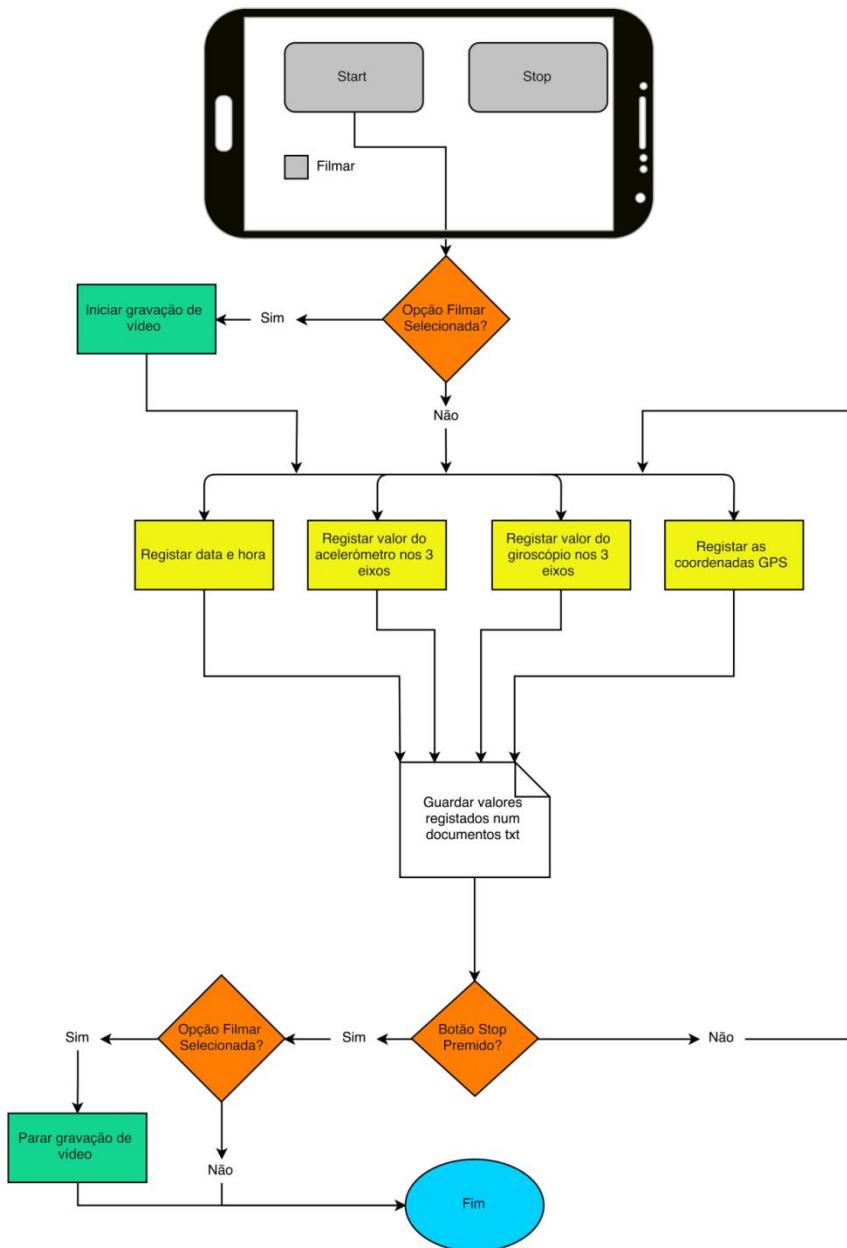


Figura 2.2.4 – Fluxograma do funcionamento da *App Bike Monitor*.



Figura 2.2.5 – Samsung Galaxy SII correndo a App desenvolvida.

Na recolha dos dados desta tese utilizou-se o modelo i9100, Galaxy SII da Samsung.

2.3 Action Cam

Para a aquisição de imagens optou-se por utilizar uma *Action Cam* em detrimento da câmara do *smartphone*, pois este tipo de câmaras possuem suportes concebidos para filmar sob condições de fortes oscilações, pelo que as imagens capturadas apresentam pouco efeito de *Rolling Shutter*.



Figura 2.3.1 – Action Cam montada no quadro da bicicleta.

A *Action Cam* foi montada na parte frontal do quadro da bicicleta em vez do guiador, pois nos testes realizados verificou-se que o ciclista está sempre a girar o guiador de forma a ajustar o equilíbrio da bicicleta. Este movimento faz com que as filmagens apresentem muito movimento lateral, como ilustra o esquema abaixo. Este movimento é indesejado e dificulta a análise das imagens.

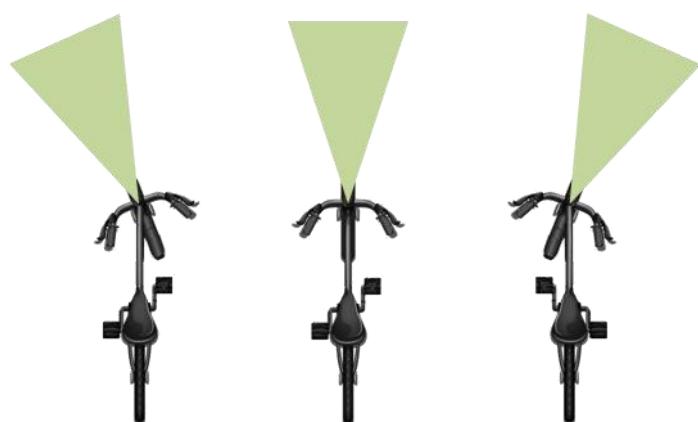


Figura 2.3.2 – Esquema da Action Cam montada no guiador.

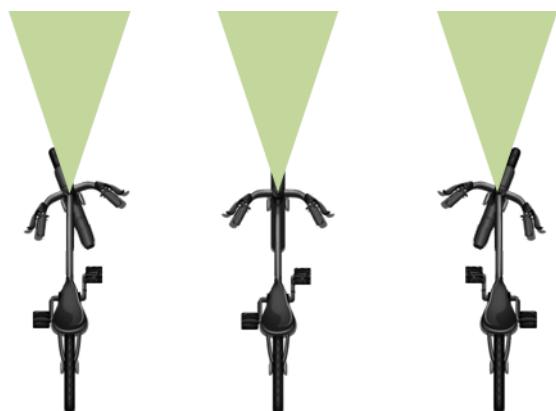


Figura 2.3.3 – Esquema da Action Cam montada no quadro.

Na recolha dos dados deste trabalho utilizou-se o modelo SJ4000 da marca Qumox.



Figura 2.3.4 – Action Cam Qumox SJ4000

2.4 Cinta cardíaca

O corpo humano possui mecanismos de adaptação fisiológica quando está perante situações de *stress* ou ansiedade, tais como: aumento da pressão sanguínea, aumento da frequência cardíaca, aumento da sudorese, diminuição do ângulo de visão (visão em túnel), dilatação das pupilas e aumento da frequência respiratória [9], [10].

Uma forma simples de detecção de ansiedade ou *stress* é através do cálculo da variabilidade cardíaca [11], vulgarmente simplificada por HRV (*Heart Rate Variability*). O cálculo do HRV é feito com base nos intervalos de tempo entre cada batimento cardíaco, intervalos RR [12].

Para a recolha dos dados cardíacos escolheu-se usar uma cinta, devido à sua simplicidade de montagem e preço reduzido, face a sistemas mais caros, complexos e desconfortáveis de usar.



Figura 2.4.1 – Cinta cardíaca colocada no peito do ciclista.

A cinta é colocada à volta do tórax do ciclista por baixo da roupa. Nesta tese, utilizou-se a cinta *BioHarness* da Zephyr que permite o registo electrocardiográfico, ECG com uma frequência de amostragem de 250 Hz. Desse sinal de ECG, extraiu-se os intervalos RR utilizados no cálculo do HRV.

Capítulo 3

Processamento dos Sinais e Detecção de Eventos

Neste capítulo explica-se como foi feita a análise dos dados recolhidos e como estes dados foram traduzidos em eventos e em estados de *stress*.

3.1 Processamento de imagem

Procedeu-se à recolha de imagens de vídeo, de modo a conseguir identificar o que acontece à volta do ciclista e a detectar situações potenciadoras de *stress*, como por exemplo o ciclista sendo ultrapassado pelo seu lado esquerdo ou detecção de buracos ou irregularidades na via.

Sobre as imagens recolhidas, foi calculada a velocidade entre imagens, o *optical flow* [13]. Posteriormente foi construído um descriptor baseado neste cálculo e finalmente um classificador baseado no algoritmo k-NN *Nearest Neighbour* (figura 3.1.1).



Figura 3.1.1 – Fluxograma do processamento de imagem

Os vídeos foram recolhidos pela *Action Cam* e apresentam um *framerate* de 30 fps e uma resolução *FullHD* de 1920x1080, também conhecida por 1080p.

Analisou-se o vídeo como uma sequência de imagens, sendo analisada uma imagem de cada vez. Efectuaram-se diferentes aproximações ao problema de análise de imagem, tais como estereoscopia, *optical flow*. Testaram-se diferentes algoritmos dos mesmos, sendo que se optou pelo cálculo do *optical flow* através do algoritmo Lukas-Kanade [14], pela sua fácil implementação e rápido processamento.

3.1.1 Cálculo do *Optical Flow*

O *optical flow* é a velocidade relativa ao movimento entre duas imagens. Neste trabalho estudou-se os padrões de movimento de várias situações potenciadoras de *stress* e a proximidade entre estes padrões permitiu identificá-las.

Para o cálculo do *optical flow* utilizou-se o algoritmo Lukas-Kanade [14], foi utilizada uma janela de pesquisa de 71 por 71 e um nível máximo da pirâmide de 3, pois foram os parâmetros que mais se ajustaram às imagens recolhidas. Este algoritmo permite estimar o movimento entre imagens consecutivas, permitindo calcular vectores de movimento (figura 3.1.2).

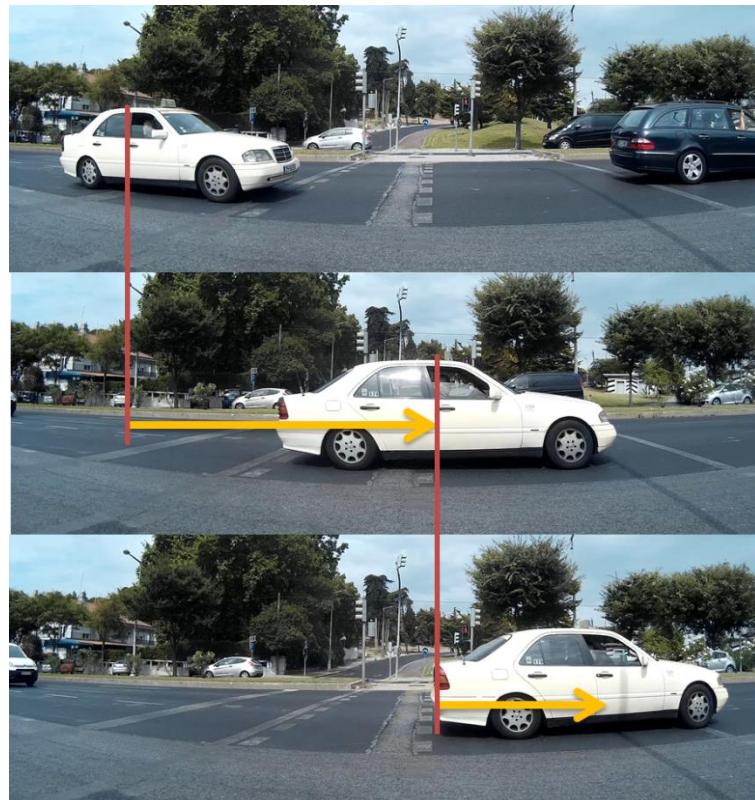


Figura 3.1.2 – Vector de movimento numa sequência de imagens.

Cada *frame* de vídeo capturado possui muita informação não relevante para o problema em estudo. Por isso, optou-se então por focar a análise apenas na zona assinalada na figura 3.1.3. Esta zona da imagem foi escolhida pois é onde todo o tráfego e os obstáculos se encontram.

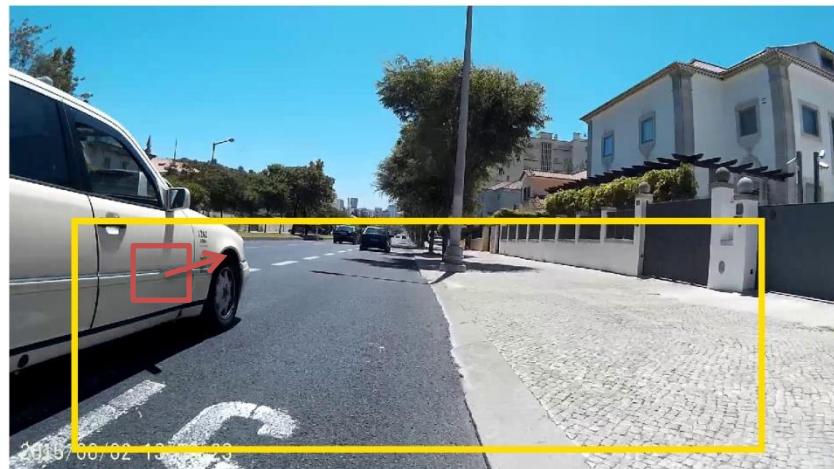


Figura 3.1.3 – Imagem com a zona de análise demarcada a amarelo.

Ainda, optou-se por pré-definir os pontos a utilizar numa janela de pontos. Esta janela permite-nos então focar na zona da imagem que é realmente importante, bem como aumentar o número de pontos processados, ao contrário do que aconteceria se utilizássemos algoritmos de *corner detection* como de *Shi-Tomasi* ou *Harris Corner Detector* [15]. Estes detectam pontos vértice (*corners*) existentes na imagem, sendo estes pontos os melhores para a aplicação de algoritmos de cálculo do *optical flow*.

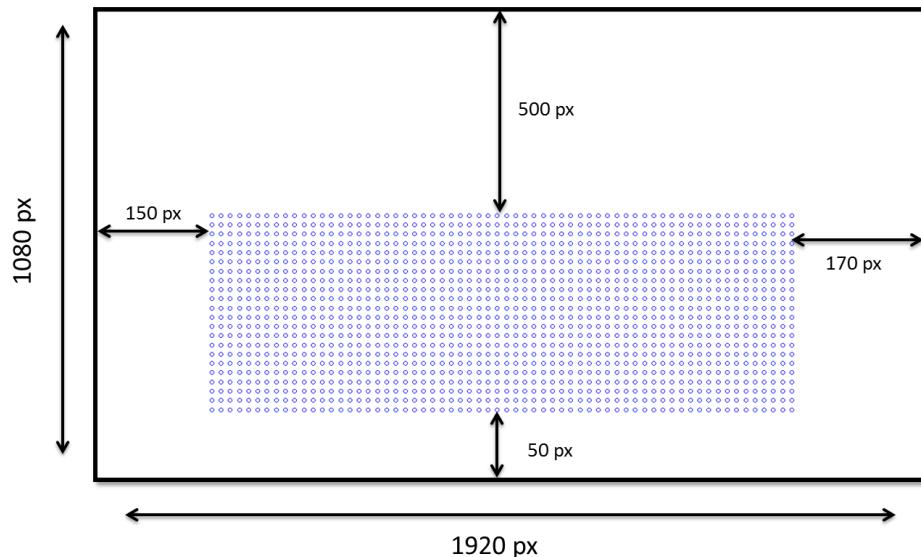


Figura 3.1.4 – Dimensões e localização da janela de pontos face ao tamanho da imagem.

A janela definida apresenta uma resolução de 1600x530, sendo que os pontos estão igualmente espaçados entre si de 25 pixéis, o que perfaz um total de 1408 pontos processados por imagem. Vários espaçamentos entre pontos foram testados, sendo que para a câmara em questão

este espaçamento foi o que apresentou melhores resultados no cálculo correcto do *optical flow*. A localização da janela de pontos face ao tamanho da imagem pode ser consultada na figura 3.1.4.

3.1.2 Filtragem do *Optical Flow*

Como referido no capítulo anterior os pontos foram pré-estabelecidos numa janela de pontos, não se aplicando nenhum método de detecção de pontos como o algoritmo de shi-tomasi. Isto faz com que o erro do cálculo do *optical flow* seja muito grande, pelo que se fez uma diferente aproximação ao problema para a remoção dos *outliers*.

Em vez de se calcular o *optical flow* apenas entre duas imagens consecutivas (figura 3.1.5), processou-se o *optical flow* entre três imagens (figura 3.1.6).

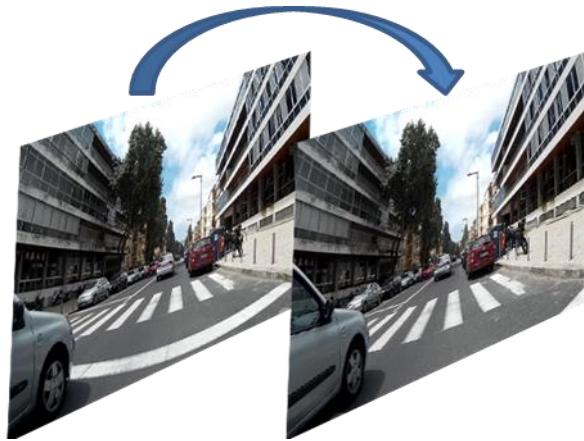


Figura 3.1.5 – Esquema do cálculo tradicional do *optical flow* entre duas imagens.

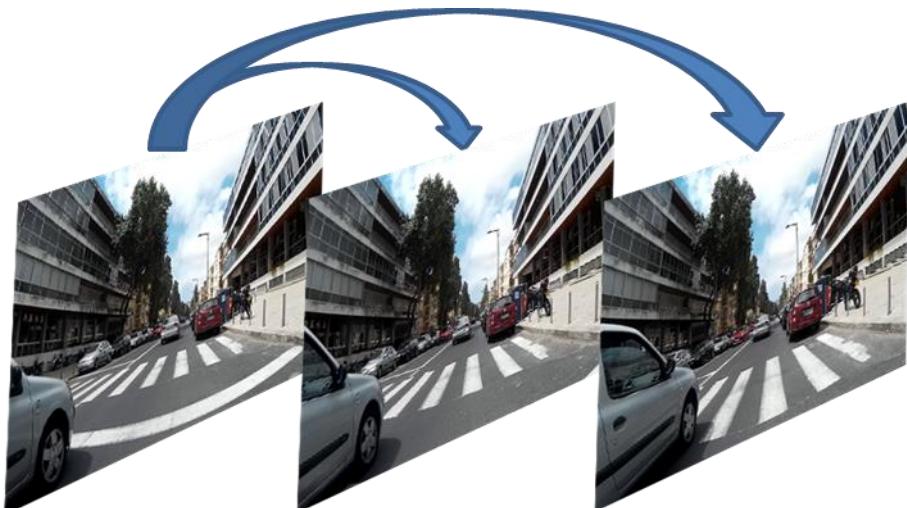


Figura 3.1.6 – Esquema adoptado para o cálculo do *optical flow* entre três *imagens*.

Como neste método são processadas três imagens, são então calculados dois vectores de *flow*: um vector referente à imagem 1 com a imagem 2 e um vector referente à imagem 1 com a imagem 3. Com base no cálculo do ângulo feito entre os dois vectores resultantes, é possível assinalar como *outliers* vectores de *flow* que tenham ângulos muito diferentes.

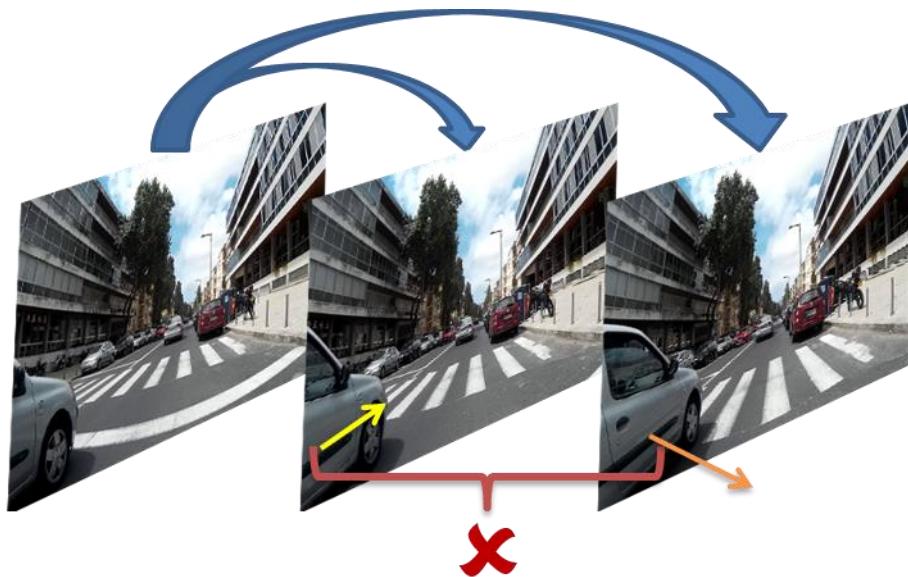


Figura 3.1.7 – Vectores com ângulos muito distintos pelo que são considerados como outliers.

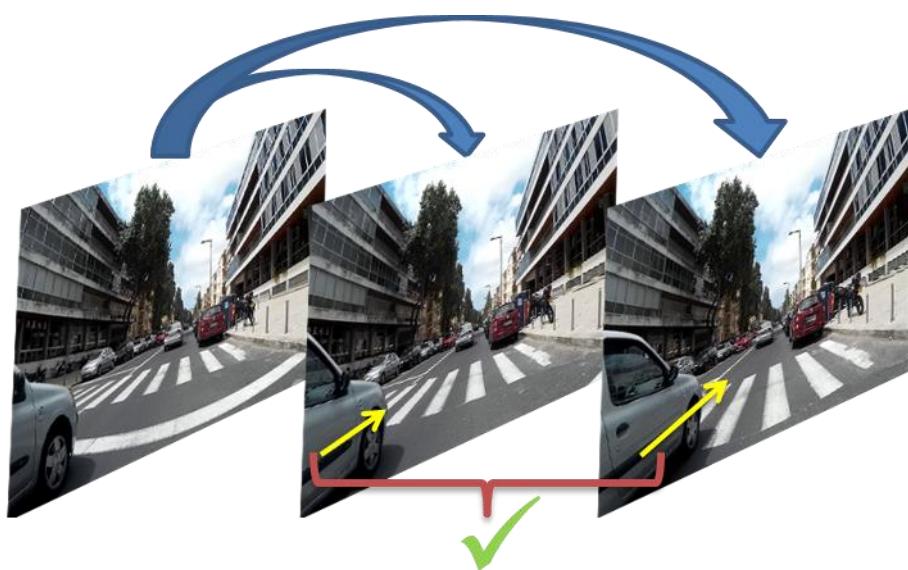


Figura 3.1.8 – Vectores considerados como inliers pelo método.

Este método permite-nos remover a maioria dos *outliers* do *optical flow* (figuras 3.1.9 e 3.1.10).

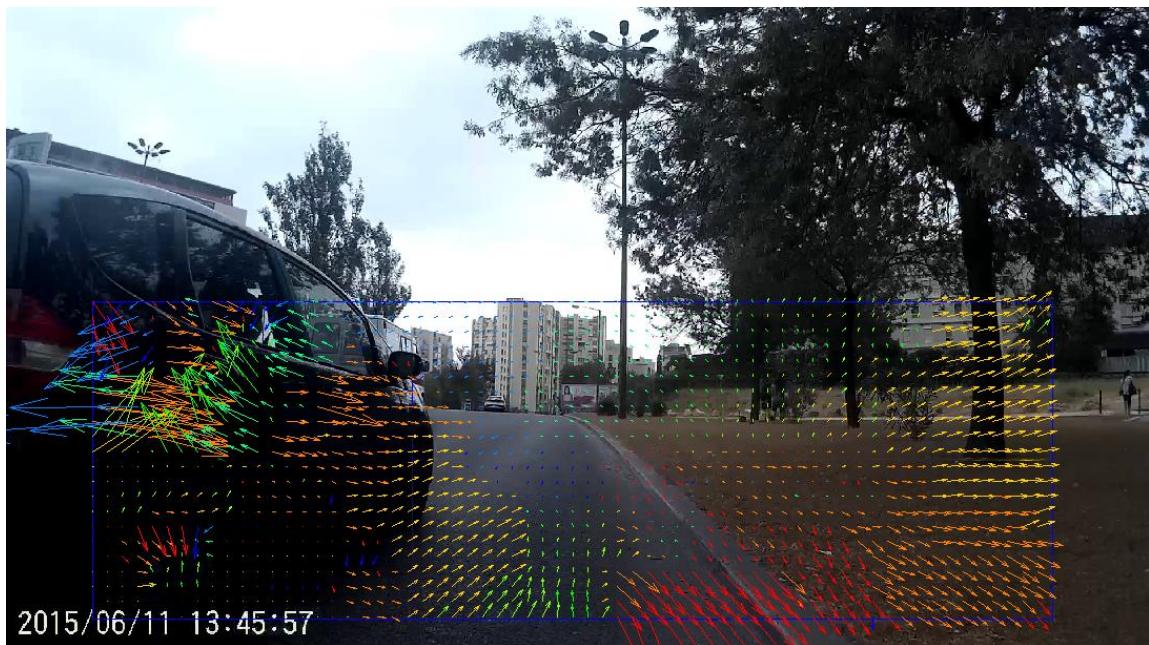


Figura 3.1.9 – *Optical flow* resultante do método tradicional entre duas imagens.



Figura 3.1.10 – *Optical flow* resultante do método adoptado entre três *imagens*.

Como podemos verificar pelo exemplo, houve uma grande redução de *outliers*, principalmente na zona do carro.

3.1.3 Descriptor da imagem

Como o objectivo da análise da imagem é classificar eventos, não é relevante o valor de *optical flow* mas sim os padrões de *optical flow* associados a cada evento. Para tal, as direcções dos vectores de *flow* calculados foram discretizadas consoante o seu ângulo em 8 intervalos igualmente espaçados entre si. Para uma fácil análise visual atribuiu-se cores a cada intervalo (figura 3.1.11).

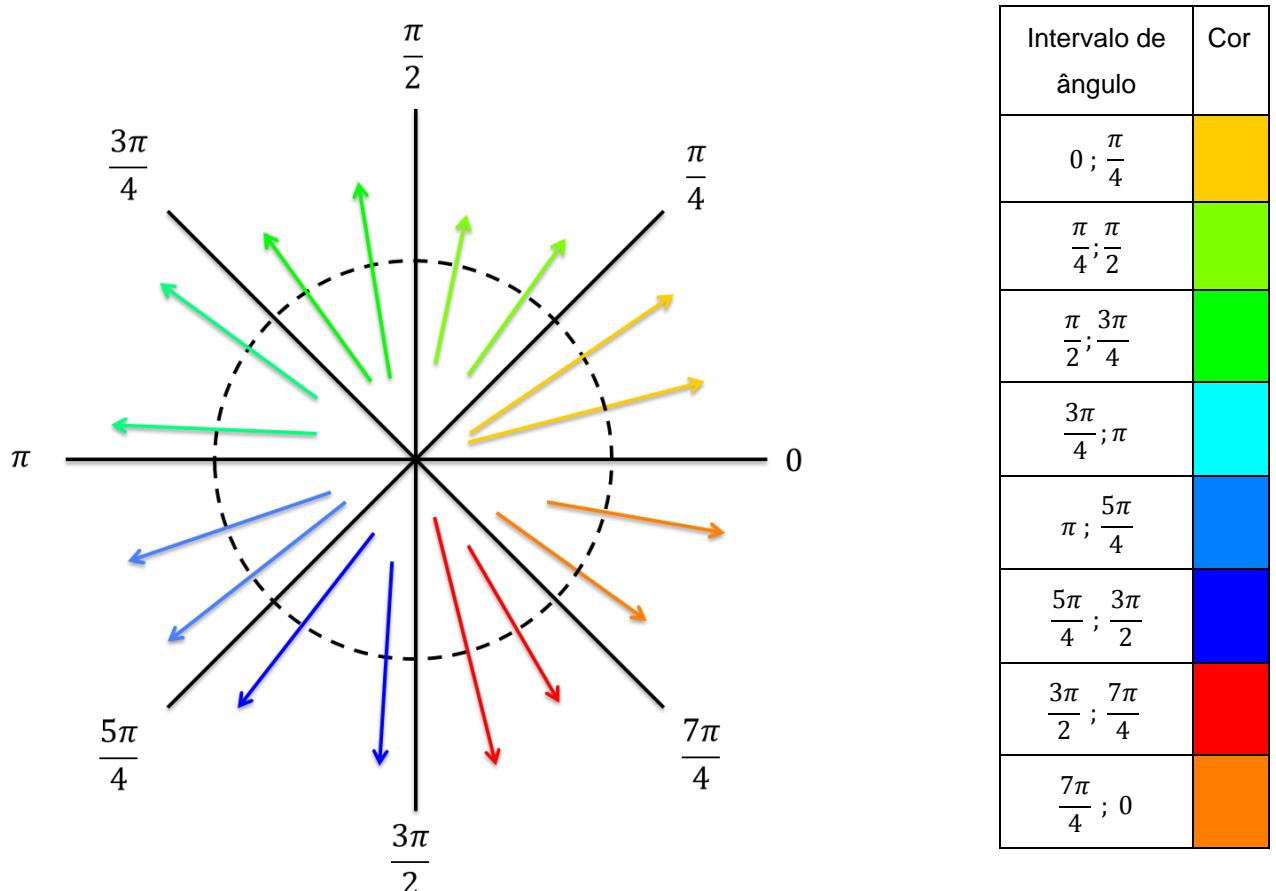


Figura 3.1.11 – Círculo trigonométrico com a discretização dos vectores do *optical flow*.

De forma a ser possível analisar o *optical flow* calculado, dividiu-se a janela em seis rectângulos iguais (figura 3.1.12).

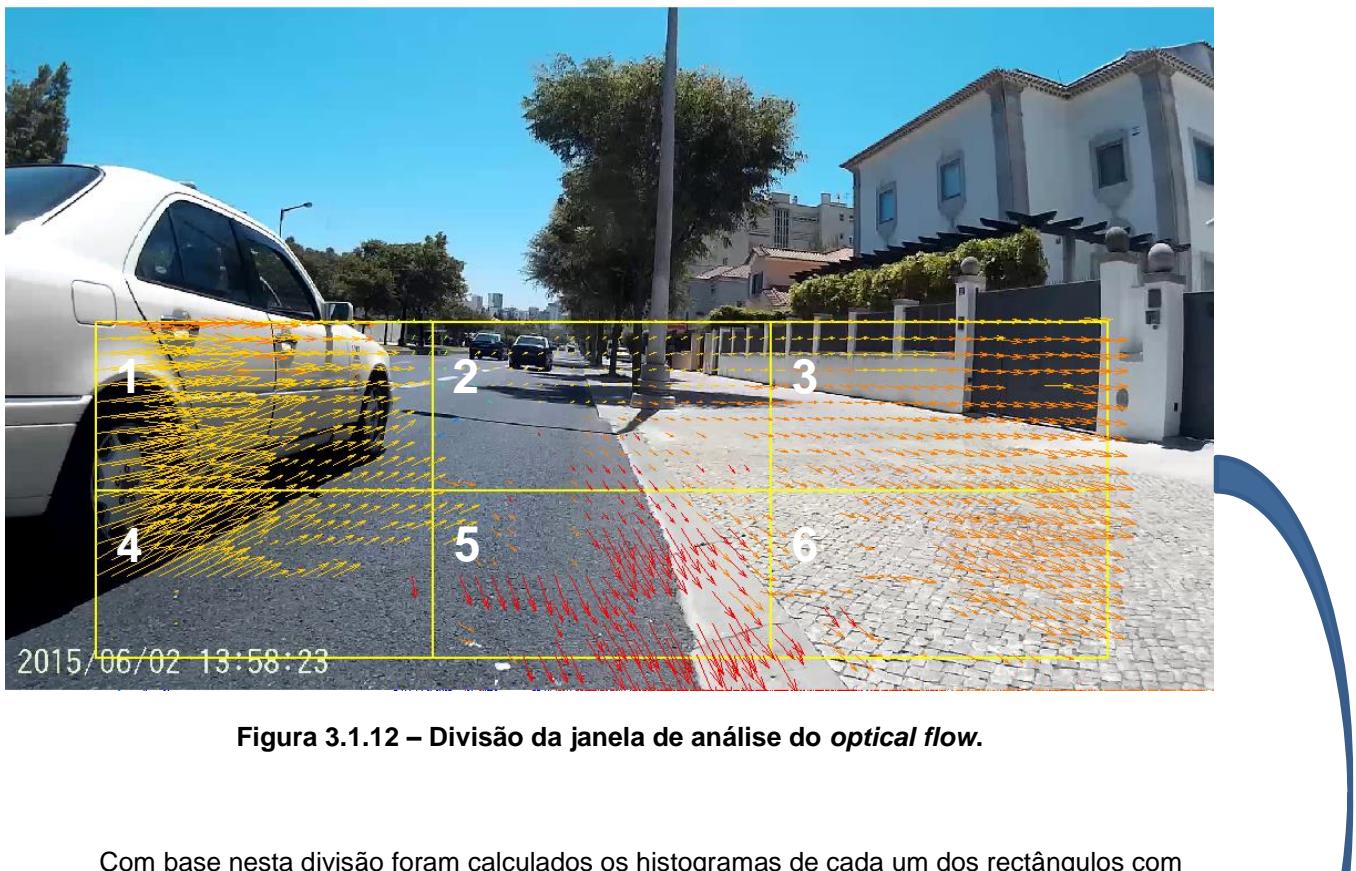


Figura 3.1.12 – Divisão da janela de análise do optical flow.

Com base nesta divisão foram calculados os histogramas de cada um dos rectângulos com base nas direcções dos vectores (figura 3.1.13).

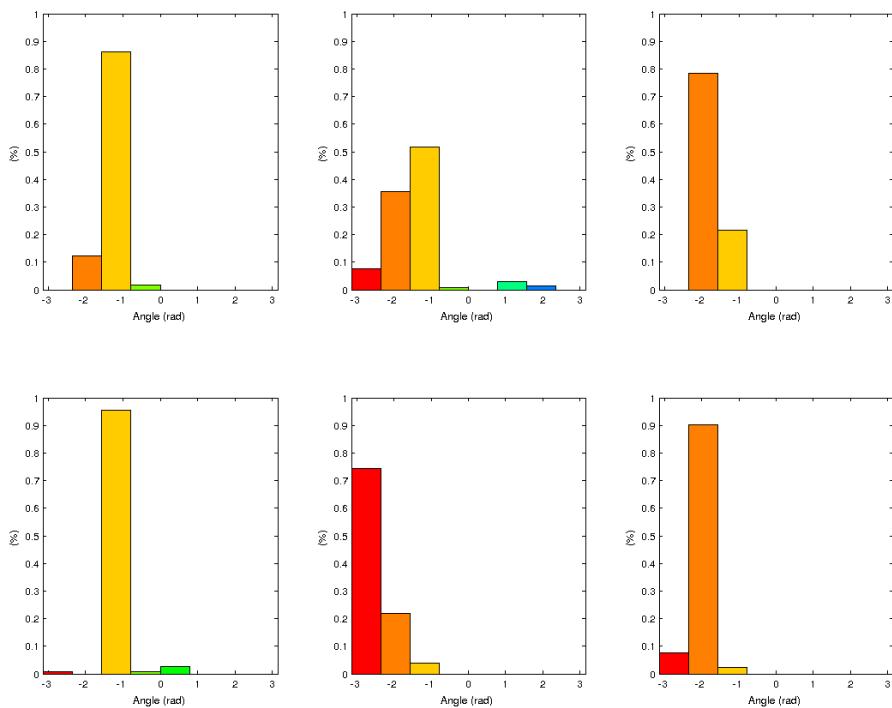


Figura 3.1.13 – Histogramas da direcção dos vectores de cada rectângulo de análise.

Com esta divisão foi também calculada a norma média dos vectores presentes em cada rectângulo (Figura 3.1.14).

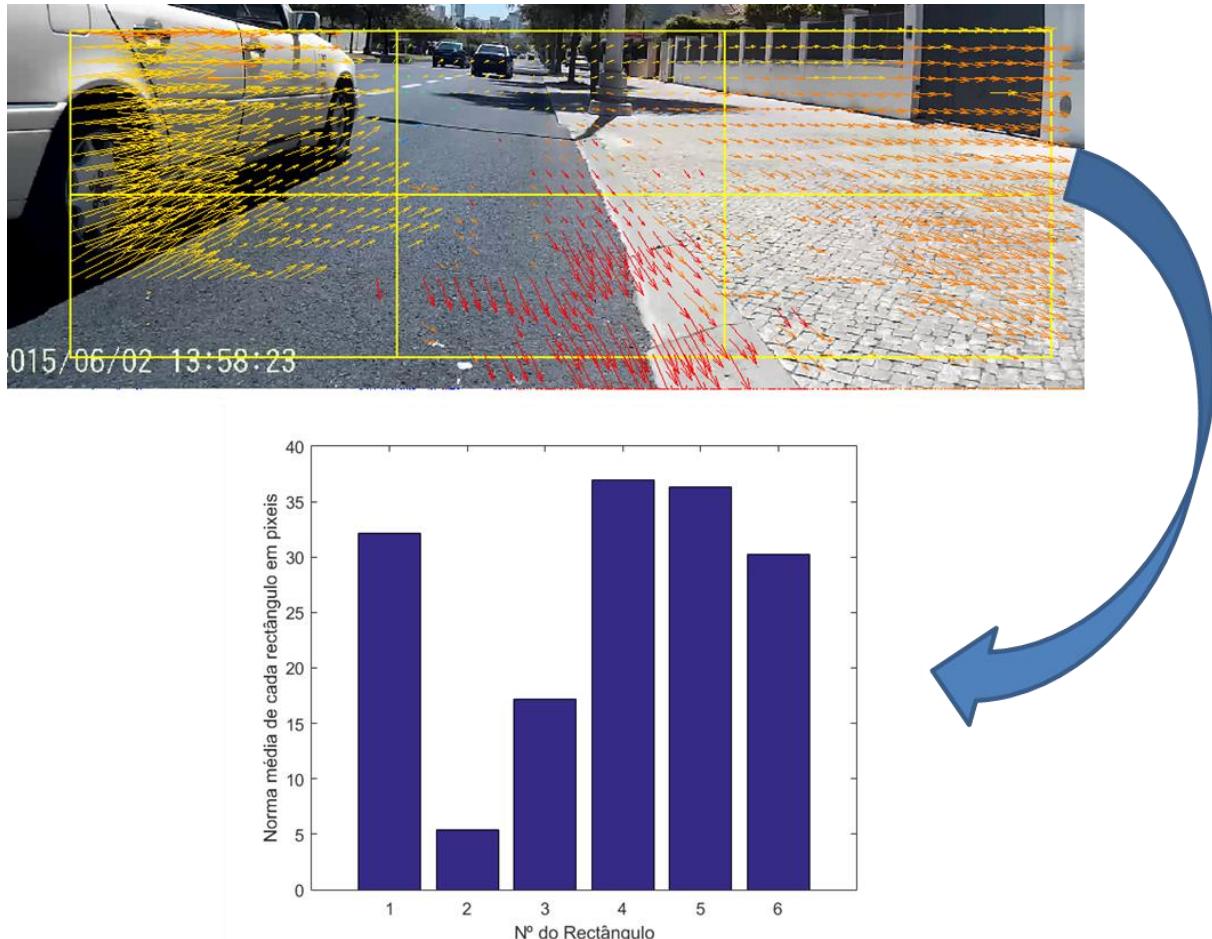


Figura 3.1.14 – Norma média dos vectores em cada rectângulo.

Em suma, para cada imagem são calculados 6 histogramas distintos, correspondentes a cada um dos rectângulos. Também é calculado por cada rectângulo a média das normas dos vectores de *flow*.

3.1.4 Classificador de eventos

Recorrendo ao descriptor definido no Cap. 3.1.3 (histogramas e norma média), foi desenvolvido um classificador de eventos.

Foram consideradas as seguintes classes:

- Ciclista parado;
- Ciclista em andamento sem obstáculos;
- Ciclista a ser ultrapassado por viatura à esquerda;
- Ciclista a virar à esquerda;
- Ciclista a virar à direita; e
- Ciclista a passar por irregularidades (buracos).

Para a génesis deste classificador procedeu-se à catalogação de 100 imagens reais, abrangendo todas as categorias acima mencionadas, exceptuando a categoria “Ciclista parado”. A classificação é então atribuída com base no algoritmo k-NN Nearest Neighbour onde é calculada a distância euclidiana entre histogramas, sendo comparados os histogramas da imagem que se quer classificar com os histogramas do catálogo. Posteriormente, são ordenadas as 10 imagens catalogadas mais próximas da imagem que se quer classificar.

Como está evidenciado nos exemplos abaixo, é possível esta classificação com base nos histogramas das direcções dos vectores.

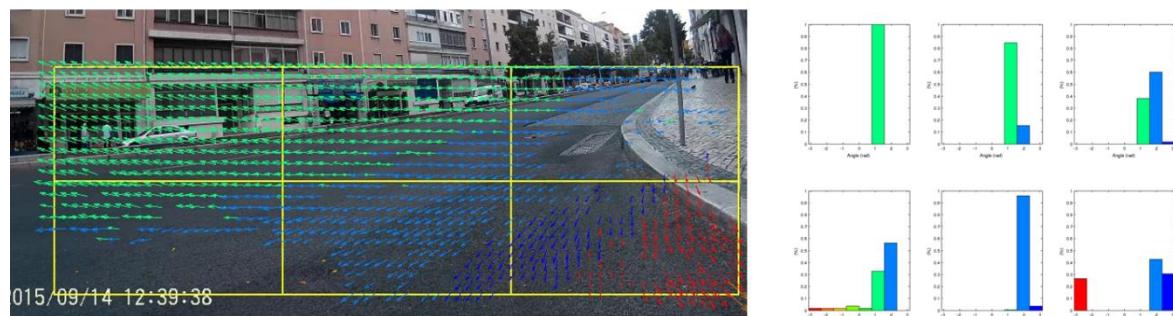


Figura 3.1.15 – Exemplo de imagem e histogramas do ciclista a virar à direita.

Como podemos verificar no exemplo da figura 3.1.15, quando o ciclista vira à direita há uma predominância de vectores com direcções entre $\frac{3\pi}{4}$ e $\frac{5\pi}{4}$ em todos os rectângulos.

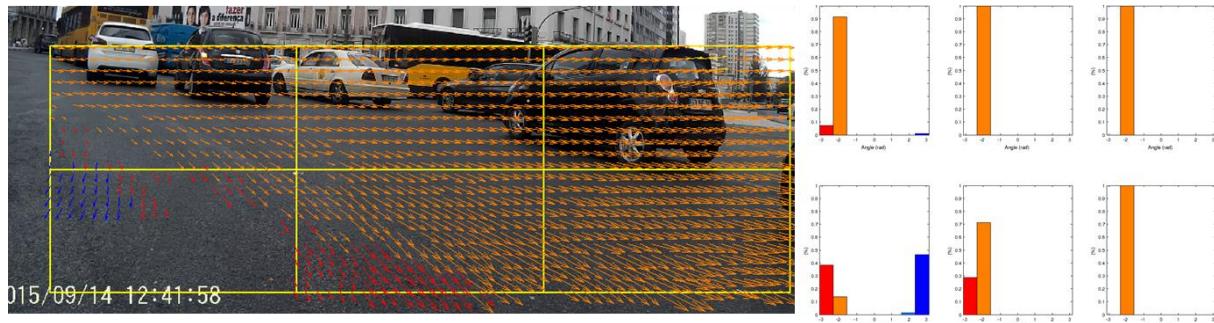


Figura 3.1.16 – Exemplo de imagem e histogramas de ciclista a virar à esquerda.

Na figura 3.1.16, verificamos que quando o ciclista vira à esquerda há maioritariamente vectores com direcções entre $\frac{7\pi}{4}$ e $\frac{\pi}{4}$ em toda a imagem.



Figura 3.1.17 – Exemplo de imagem e histogramas de ciclista a ser ultrapassado pela esquerda.

Quando o ciclista é ultrapassado pela esquerda (figura 3.1.17), os histogramas do primeiro e por vezes do quarto rectângulo apresentam uma alta quantidade de vectores com direcções entre 0 e $\frac{\pi}{4}$, ficando os histogramas dos restantes rectângulos inalterados.

A situação de “Ciclista parado” é calculada com base na norma média dos vectores de *flow*. Assim, quando a média da norma dos vectores de *flow* é reduzida ou nula é identificada a situação de “Ciclista parado”.

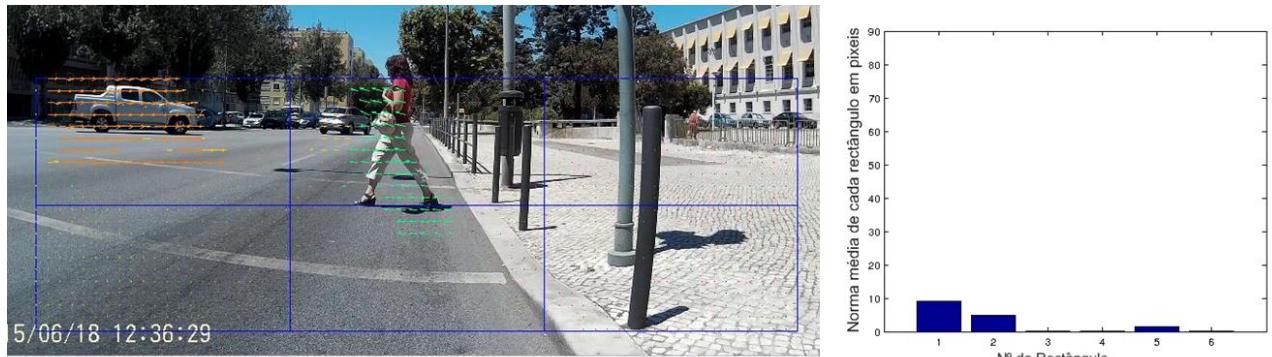


Figura 3.1.18 – Imagem e norma média dos vectores numa situação bem classificada de “ciclista parado”.

Como podemos inferir da imagem 3.1.18, a imagem apresenta vectores de *flow* pequenos pelo que se trata de uma situação de ciclista parado.

Contudo esta aproximação possui uma limitação. Quando o ciclista se encontra parado e à sua frente há muito movimento, como por exemplo cruzamentos com carros em circulação, este identifica como ciclista em movimento. No entanto, esta limitação pode ser ultrapassada comparando com as coordenadas GPS (Figura 3.1.19).

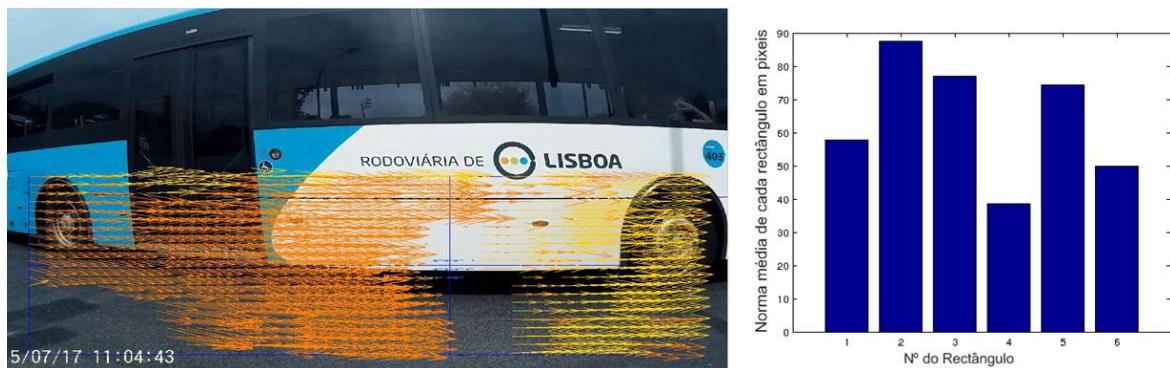


Figura 3.1.19 – Imagem e norma média dos vectores, ciclista está parado mas há muito movimento à sua frente, levando a uma classificação errada do evento.

3.1.4.1 Avaliação do classificador de eventos

O classificador apresentado em 3.1.4 tem algumas falhas, dado que por vezes os histogramas das imagens são muito parecidos, pelo que este retorna falsos positivos, principalmente entre a categoria “ciclista a virar à esquerda” e “ciclista a ser ultrapassado pela esquerda”. Isto deve-se ao facto de as duas categorias serem muito semelhantes.

Para evidenciar esta limitação construiu-se uma matriz confusão onde se classificou todas as

imagens catalogadas do classificador com o próprio classificador. A matriz confusão evidencia que realmente a categoria “ciclista a virar à esquerda” é frequentemente mal classificada como “ciclista ultrapassado pela esquerda” (Figura 3.1.20).

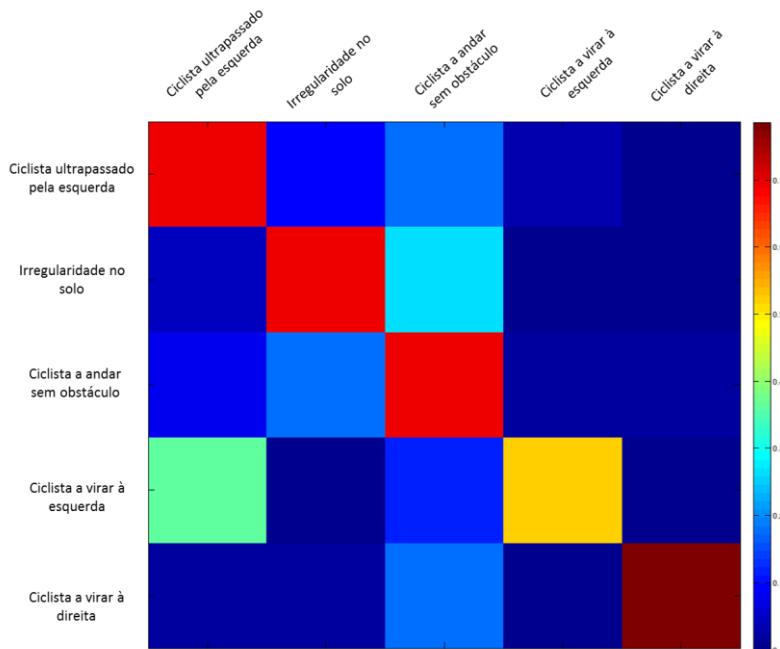


Figura 3.1.20 – Matriz confusão construída a partir das imagens classificadas.

Como a classificação foi baseada num top 10, procedeu-se ao estudo do número médio de imagens classificadas correctamente nesse top 10 (Figura 3.1.21).

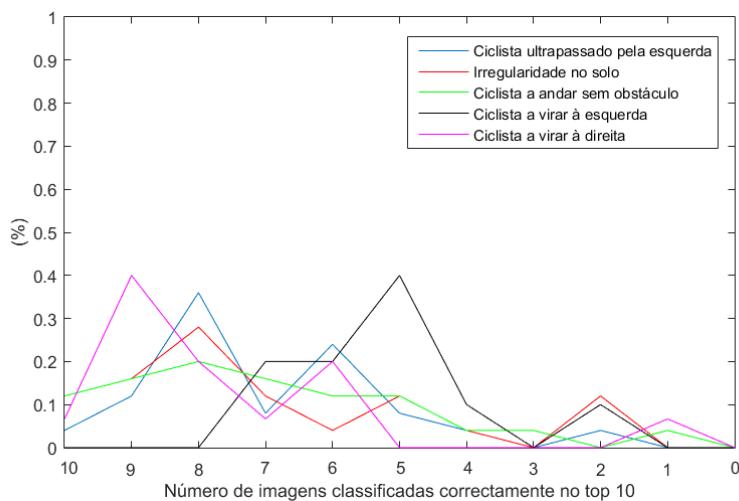


Figura 3.1.21 – Número médio de imagens classificadas correctamente no top 10 em cada classe.

Mais uma vez, voltou-se a verificar a limitação da categoria “ciclista a virar à esquerda”

3.1.5 Detecção de obstáculos na berma

Como os ciclistas circulam maioritariamente junto à berma da estrada, pretende-se detectar a proximidade de potenciais objectos ou obstáculos presentes nas bermas e passeios. Esta detecção é feita com base no tamanho dos vectores do *optical flow*. Quanto mais próximo o objecto se encontra da câmara e consequentemente do ciclista, maior será o seu vector de *optical flow*.

Através da norma média dos vectores de cada rectângulo referida no capítulo 3.1.3, foi calculada a proximidade do ciclista aos objectos e/ou obstáculos que se encontram na berma. Como veremos mais adiante, um obstáculo é detectado quando a norma média dos vectores do terceiro quadrado é elevada.

Para este cálculo normalizou-se os vectores de toda a janela de análise da imagem. Procedeu-se à comparação da média da norma dos vectores do terceiro rectângulo com a média geral das normas de todos os rectângulos (figura 3.1.22).

Esta normalização torna invariante a velocidade do ciclista. Se o ciclista estiver a circular rapidamente, os vectores de *flow* serão grandes em toda a imagem e maiores ainda no terceiro rectângulo caso a berma esteja obstruída. Se o ciclista estiver a circular devagar, os vectores serão todos pequenos, sendo que os vectores do terceiro rectângulo serão um pouco maiores caso a berma esteja obstruída.

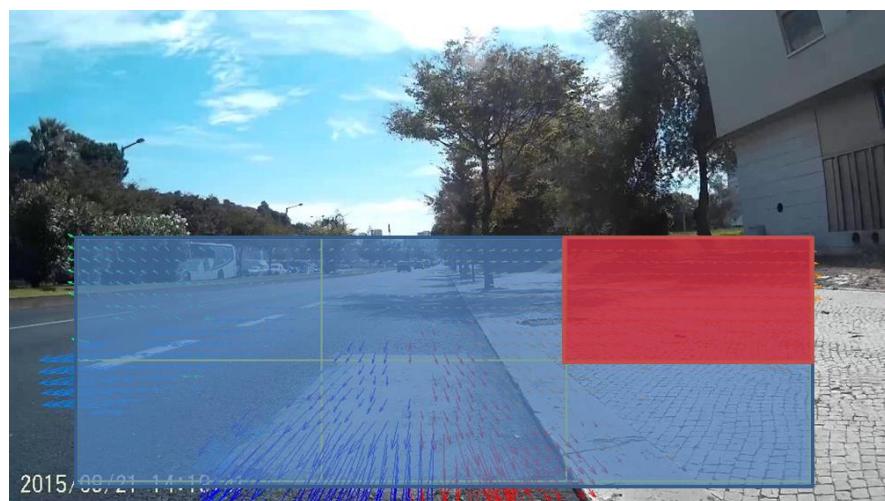


Figura 3.1.22 – Janela de análise com marcação do rectângulo usado no cálculo da proximidade da berma

Posto isto, foi então calculado uma razão entre a média das normas do terceiro rectângulo e a média das normas da janela de análise. Quanto maior este ratio mais próximo se encontra o ciclista de eventuais obstáculos na berma.

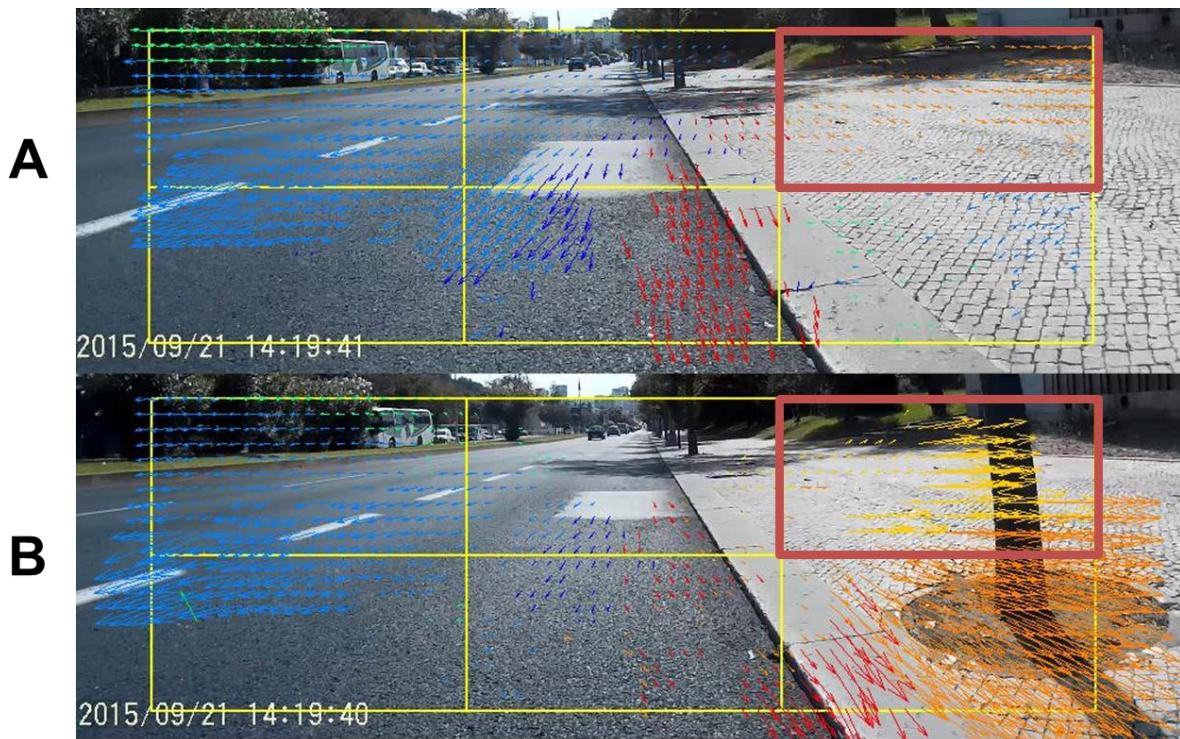


Figura 3.1.23 – Obstrução de bermas: imagem A - Berma desobstruída, imagem B - Berma com obstrução.

Na imagem A, não há obstrução da berma e é possível verificar que a norma dos vectores da terceira janela é relativamente baixa quando comparada com os vectores de toda a imagem. Na imagem B, há obstrução da berma, sendo possível verificar que a norma dos vectores da terceira janela é relativamente maior quando comparada com os vectores de toda a imagem (figura 3.1.23).

3.2 Detecção de irregularidades na via usando o acelerómetro.

Como foi mencionado no Cap. 2.2, o *smartphone* foi montado no guiador da bicicleta, pelo que foi atribuído o sistema de eixos evidenciado na figura 3.2.1 para o processamento dos dados dos sensores.

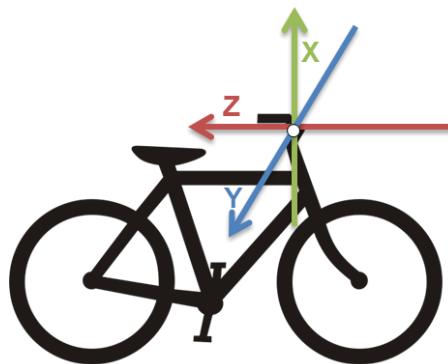


Figura 3.2.1 – Referencial ao sistema bicicleta.

Com os dados recolhidos do acelerómetro do *smartphone* foi possível identificar irregularidades na via, como buracos, lombas e valas.

Quando a bicicleta passa por uma destas irregularidades no solo, é registada uma oscilação no eixo X do referencial estabelecido (figura 3.2.2).

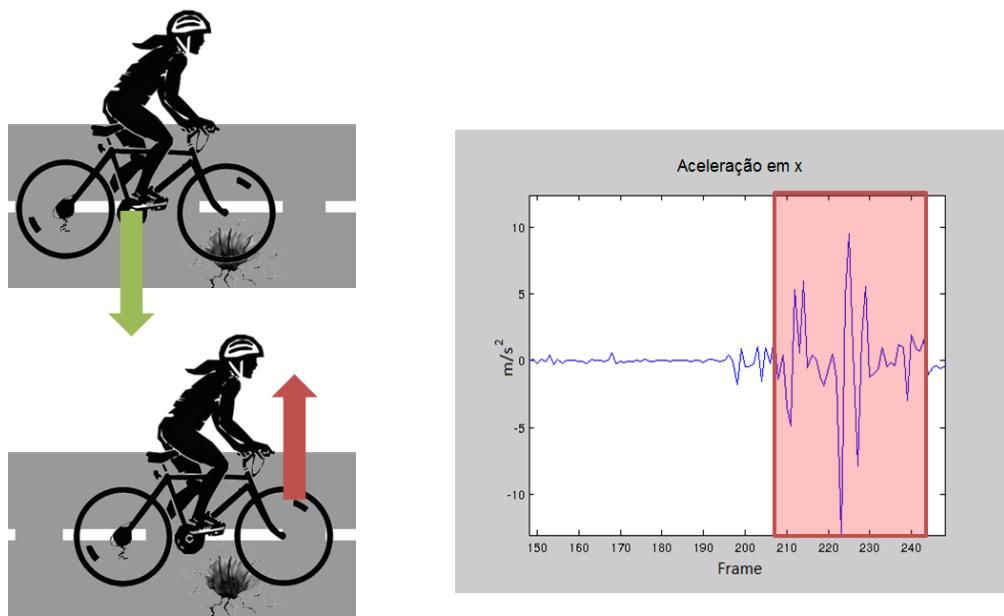


Figura 3.2.2 – Esquema da detecção de irregularidade na via.

Esta oscilação depois de detectada é então registada, permitindo-nos mais tarde verificar pelas imagens recolhidas a via em questão.



Figura 3.2.3 – Buraco na via detectado pelo sistema desenvolvido.

3.3 Processamento do ECG

De modo a ser possível determinar o estado de *stress* do ciclista, procedeu-se ao registo electrocardiográfico (ECG) do mesmo. Através do registo ECG, foi calculada a HRV como iremos ver no decorrer deste capítulo. Neste subcapítulo é explicada de forma sucinta o funcionamento básico do ciclo cardíaco, de forma a explicar como é deduzido o estado de *stress* do mesmo.

3.3.1 Funcionamento básico do ciclo cardíaco

O ciclo cardíaco é controlado de forma autónoma pelo seu sistema próprio de condução eléctrica, composto pelo Nódulo Sinusal, Nódulo Aurículo-ventricular e restantes ramos que conduzem o estímulo. Esse sistema sofre influência do sistema nervoso autónomo simpático e parassimpático. O sistema nervoso simpático é responsável pelo aumento da frequência cardíaca e predomina em situações de *stress*, enquanto que o sistema nervoso parassimpático é responsável pelo estado basal de funcionamento do organismo e, assim, por uma diminuição da frequência cardíaca [12].

A frequência cardíaca é mantida à custa de um equilíbrio simpático-parassimpático, sendo que, quando a frequência cardíaca aumenta, assiste-se a um aumento da estimulação simpática, com diminuição da estimulação parassimpática [16]. De forma oposta, o mesmo acontece quando a frequência cardíaca diminui, havendo predomínio parassimpático. Em situações de *stress*, o estado basal do organismo é alterado, havendo uma acentuação da resposta simpática [16].

Uma forma de calcular a predominância destes sistemas, simpático ou parassimpático, é através da variabilidade cardíaca, HRV [17].

3.3.2 Cálculo do HRV

Como mencionado no capítulo 2.4, foi utilizada uma cinta cardíaca de onde se recolheu os intervalos de tempo entre cada batimento cardíaco: *inter-beat* (RR). Os valores destes intervalos permitem-nos então o cálculo do HRV [12].

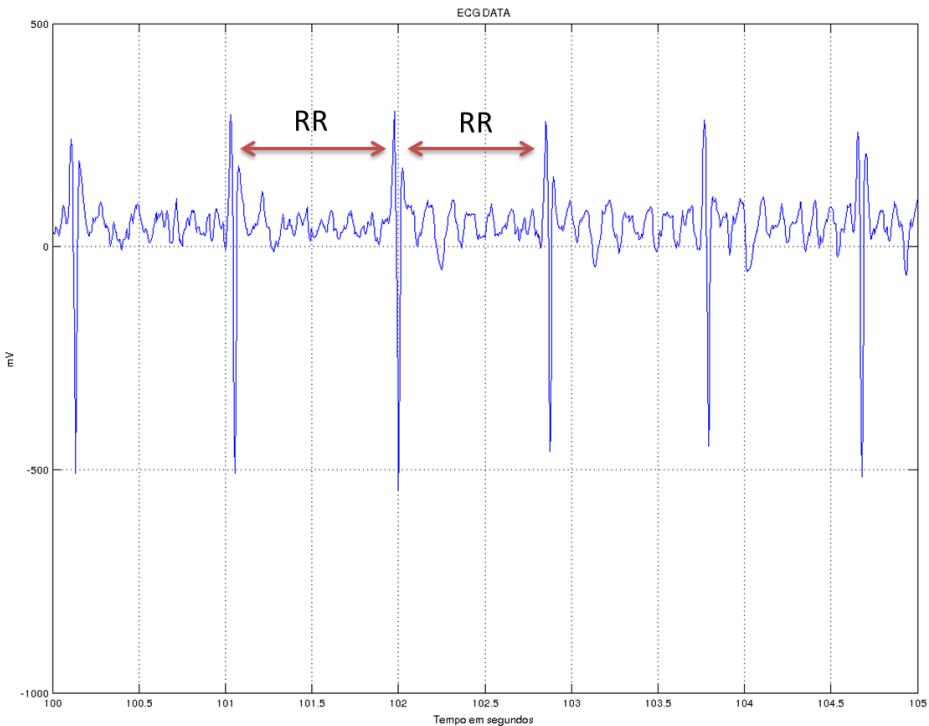


Figura 3.3.1 – Intervalos RR representados num ECG.

Para a determinação do HRV, é calculada a densidade espectral de potência dos intervalos RR. Do espectro resultante interessa-nos os seguintes dois intervalos:

- Low Frequency (LF): 0,04 Hz a 0,15 Hz – representa a estimulação simpática [17].
- High Frequency (HF): 0,15 Hz a 0,4 Hz – representa a estimulação parassimpática [17].

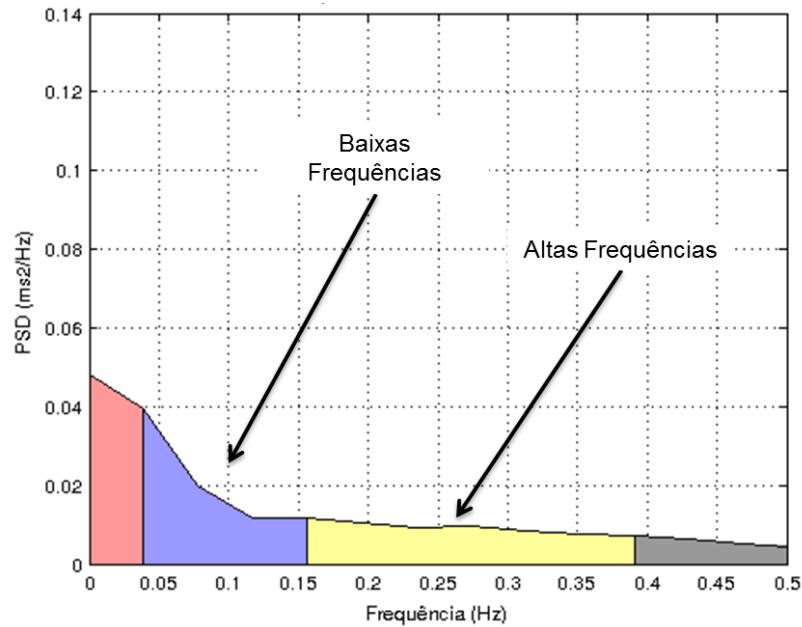


Figura 3.3.2 – PSD dos intervalos RR.

De acordo com o mecanismo fisiológico, em situações de *stress* há maior energia nas LF em detrimento de uma menor energia nas HF (figura 3.3.4). Para a determinação do *stress* do ciclista foi calculado o ratio LF/HF da seguinte forma:

Seja $RR(t)$ a variação dos intervalos RR ao longo do tempo t e $S_{RR}(f)$ a densidade espectral de potencia de $RR(t)$ temos que:

$$\frac{LF}{HF} = \frac{\int_{0.05}^{0.15} S_{RR}(f) df}{\int_{0.15}^{0.4} S_{RR}(f) df},$$

Não há consenso acerca de valores normais para o ratio LF/HF, sendo que este varia de indivíduo para indivíduo, com base na sua idade, altura, peso condição física e saúde cardíaca [18][19]. Assim, este ratio deverá ser analisado pela sua variação ao longo do percurso.

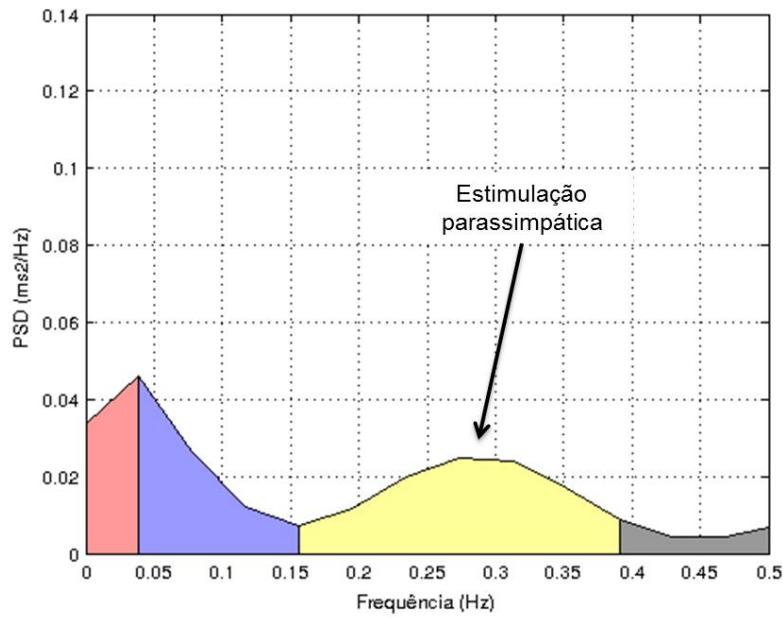


Figura 3.3.3 – PSD com o domínio da estimulação parassimpática.

Na figura 3.3.3 podemos verificar uma estimulação parassimpática, havendo domínio das altas frequências.

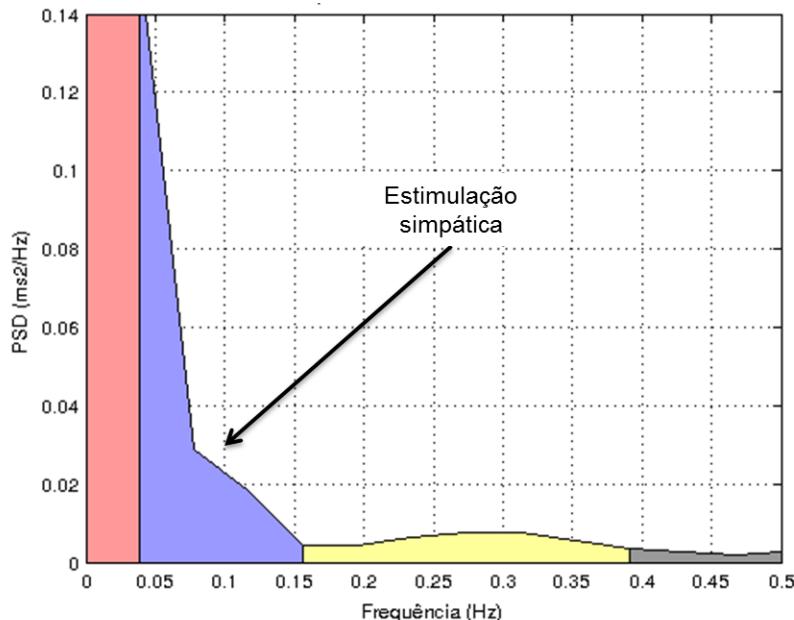


Figura 3.3.4 – PSD com domínio da estimulação simpática.

No entanto, estudos demonstram que no início de sessões de exercício físico a estimulação simpática é acentuada, aumentando assim as baixas frequências e consequentemente o valor do ratio LF/HF. Após a estabilização do valor de VO₂ (Consumo de oxigénio), a estimulação diminui, retomando níveis normais [20].

Dada a natureza deste trabalho, os dados analisados terão de ter em conta esta acentuação durante níveis de maior esforço físico dos ciclistas. Assim, consegue-se que estas acentuações não sejam interpretadas como falsos positivos de *stress*.

Para o cálculo do HRV, fez-se uma interpolação dos intervalos RR, com uma frequência de amostragem de 10Hz através do método de *Spline*. Posto isto, foi calculada a PSD através do método de *Welch*, com uma janela de 256 amostras e uma janela de *overlap* de 50%. Esta análise foi feita com base em períodos de amostragem de 2min, sendo que a bibliografia recomenda um registo mínimo de entre 1 min a 5min [21].

Capítulo 4

Análise do Sistema Experimental em Ambiente Real

Este capítulo foca-se no comportamento do sistema experimental desenvolvido em ambiente real.

No decorrer deste trabalho foram feitos vários percursos de teste, sendo que foi construída uma base de dados onde estão disponibilizados todos dados destes percursos. Foram recolhidas cerca de 2h00 de dados que correspondem a um total 10 percursos, 8 deles na cidade de Lisboa e 2 deles na cidade de Ponta Delgada. Estes percursos possuem os seguintes dados devidamente sincronizados:

- Georreferenciação GPS
- Vídeo
- Registo electrocardiográfico (ECG)
- Aceleração nos 3 eixos (Acelerómetro)
- Rotação nos 3 eixos (Giroscópio)

Neste capítulo iremos apenas abordar um percurso exemplo feito na cidade de Lisboa, entre o Instituto Superior Técnico e a R. Pardal Monteiro. Este teve lugar no dia 14 de Setembro de 2015, pelas 14h.

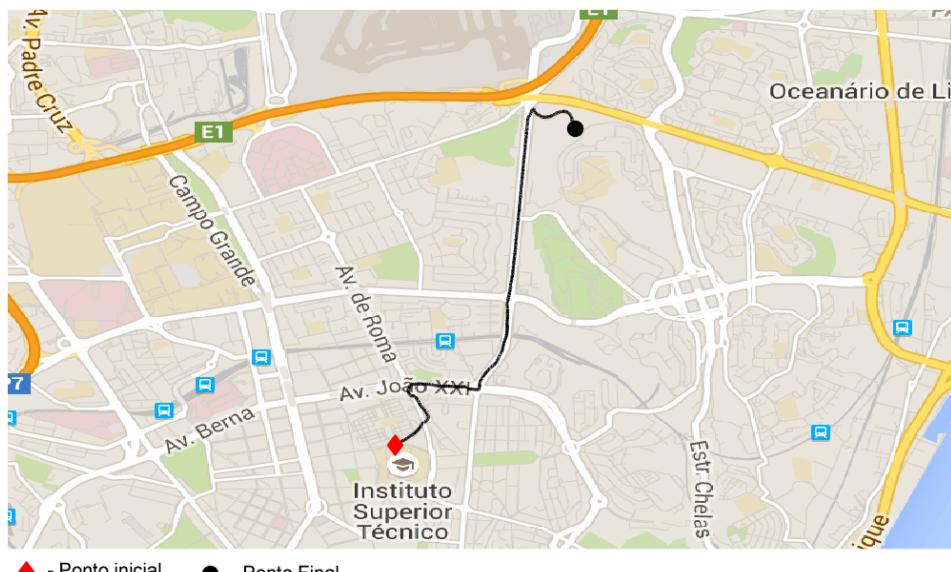


Figura 3.3.1 – Mapa do percurso exemplo em análise

Através dos métodos descritos no capítulo 3, serão analisadas as seguintes variáveis:

- Variabilidade cardíaca (*stress*)
- Variáveis potenciadores de *stress*:
 - Velocidade do Ciclista
 - Proximidade de obstáculos na berma
 - Ciclista a ser ultrapassado pela esquerda
 - Irregularidades na via

4.1 Factores potenciadores de *stress*

O meio urbano apresenta vários factores de *stress*, nomeadamente o tráfego, as condições da via, a velocidade e o ambiente circundante. Estes factores foram tidos em conta e foram detectados nestes percursos.

4.1.1 Velocidade do ciclista

Através dos dados GPS recolhidos foi calculada a velocidade do ciclista ao longo do percurso, ilustrada no mapa da figura 4.1.1.

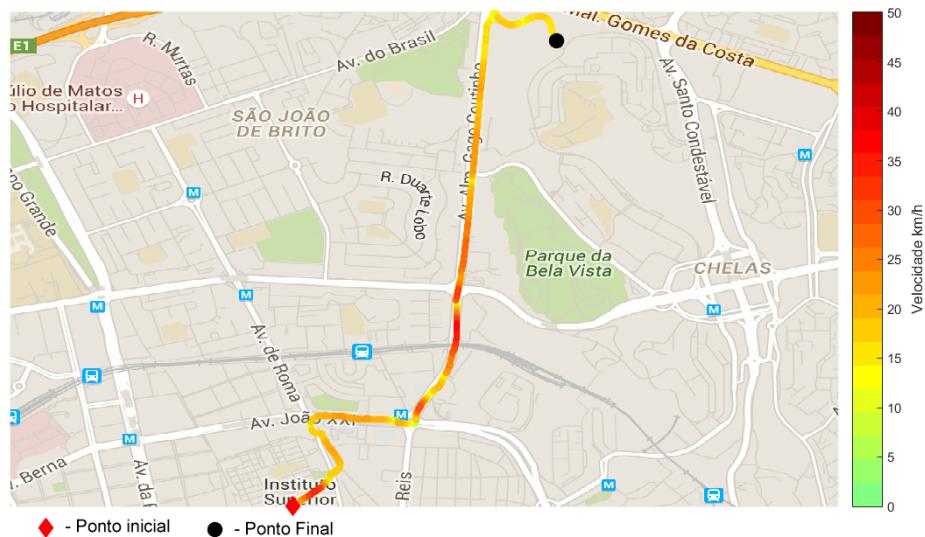


Figura 4.1.1 – Mapa da velocidade ao longo do percurso.

As zonas mais vermelhas do mapa correspondem a zonas de maior velocidade. Por oposição, as zonas mais amareladas correspondem a zonas de menor velocidade.

4.1.2 Proximidade de obstáculos na berma

Como referido no capítulo 3.1.5, foi calculado a razão de proximidade da berma, o que permite saber se existe ou não espaço disponível ao lado do ciclista.

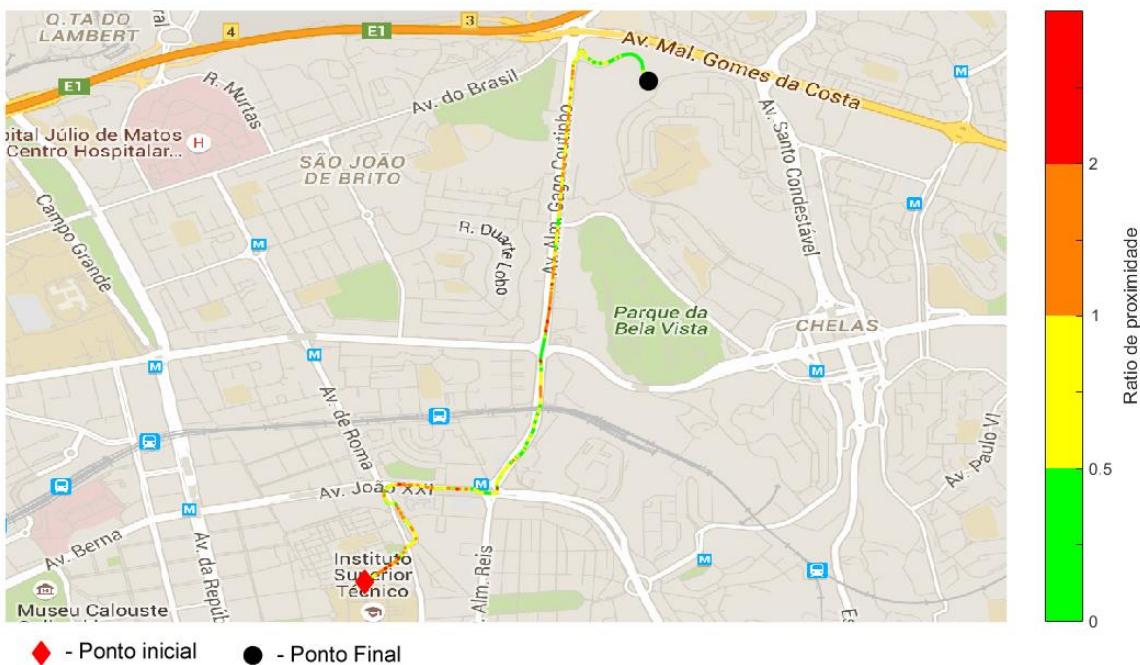


Figura 4.1.2 – Razão da proximidade da berma.

Quanto mais próximos estão os obstáculos da berma, maior a razão, correspondendo às zonas mais encarnadas. Quando há espaço livre na berma o ratio desce, estando assinalado no mapa pela cor verde.

Utilizando o cruzamento da Av. Almirante Gago Coutinho com a Av. Mal. António de Spínola como exemplo, pode-se identificar duas situações distintas de obstrução da berma (figura 4.1.3).

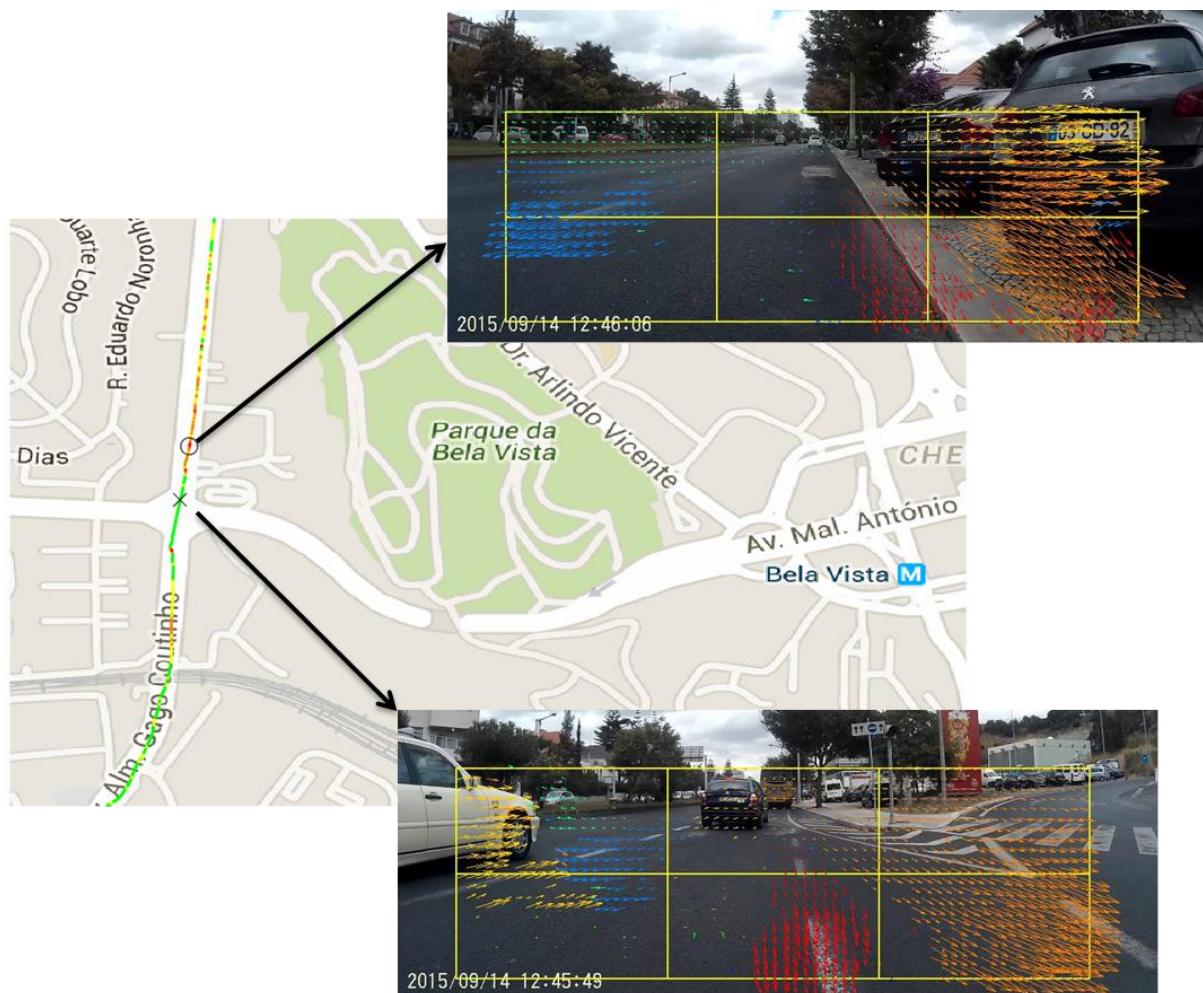


Figura 4.1.3 – Situação A – Berma obstruída. Situação B – Ciclista num cruzamento, berma desobstruída.

Na situação A, a berma encontra-se obstruída por carros. Esta situação poderá ser causadora de stress, uma vez que o ciclista não possui espaço para onde se possa desviar no caso de um imprevisto. Já na situação B o ciclista possui espaço livre caso se pretenda desviar no caso de algo inesperado ocorrer.

4.1.3 Ciclista a ser ultrapassado pela esquerda

De acordo com o estabelecido no capítulo 3.1.4, foi também desenvolvido um classificador baseado no algoritmo k-NN *Nearest Neighbour*, permitindo detectar se o ciclista está a ser ultrapassado pelo lado esquerdo.

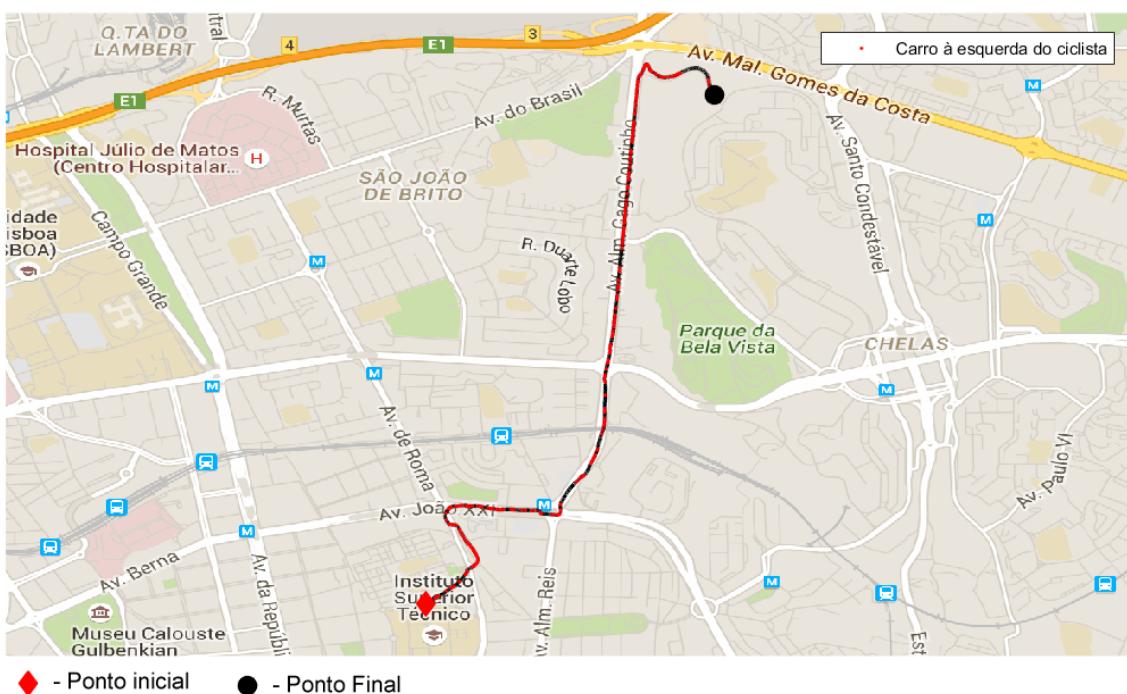


Figura 4.1.4 – Distribuição do evento “Ultrapassado pela esquerda” ao longo do percurso.

Uma limitação deste método de detecção prende-se com o facto de retornar por vezes falsos positivos, por haver histogramas muito próximos. O falso positivo mais comum acontece quando o ciclista vira à esquerda, pois neste caso os histogramas são muito parecidos e o sistema tem dificuldade em distinguir estes dois eventos.



Figura 4.1.5 – Ponto O - Evento bem detectado. Ponto X – Falso positivo

O Ponto X corresponde a um falso positivo do evento “ciclista ultrapassado pela esquerda”, enquanto que o Ponto O corresponde a um evento bem identificado (figura 4.1.5; figura 4.1.6).



Figura 4.1.6 – Imagens do ponto O e ponto X

Comparando as duas imagens, constata-se que as direcções dos vectores do *optical flow* são muito semelhantes.

Esta limitação pode ser, no entanto, ultrapassada, se apenas se contabilizarem conjuntos de imagens consecutivas que tenham sido classificados com o mesmo evento. Isto é, os falsos positivos ocorrem isolados no vector de classificação, ao contrário do que acontece nos eventos bem classificados.

4.1.4 Irregularidades na via

Como abordado anteriormente nos capítulos 3.1.4 e 3.2, foram desenvolvidas duas formas de classificar o evento “Irregularidades na via”. Um dos métodos utiliza o sensor óptico e o outro o acelerómetro do *smartphone*.

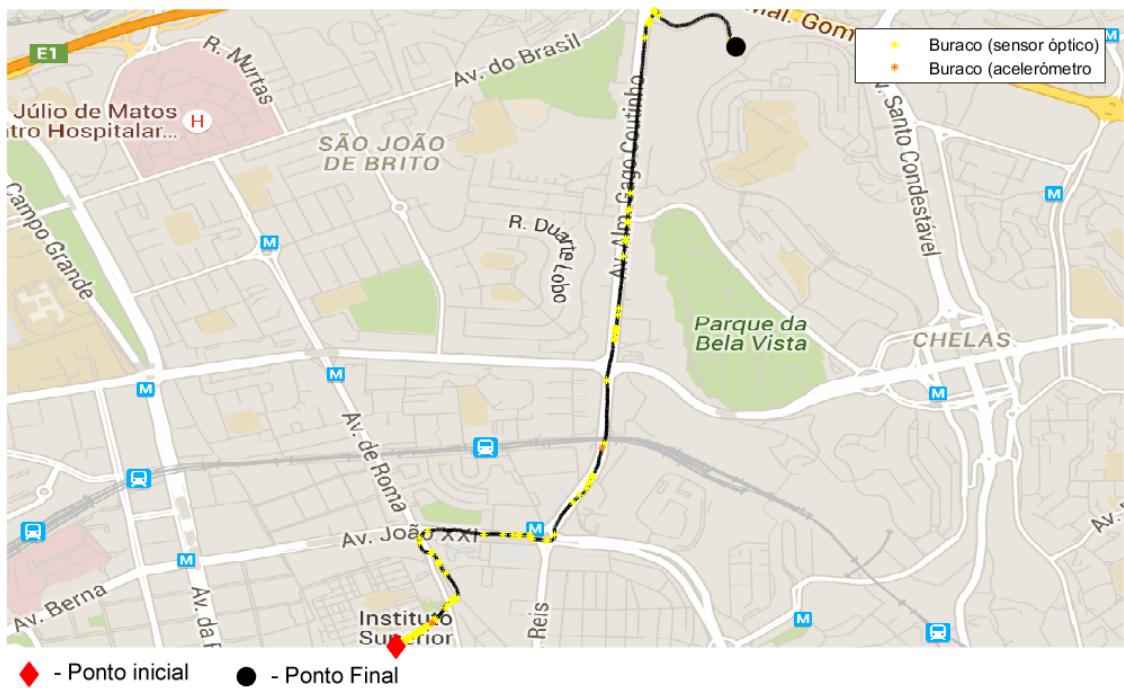


Figura 4.1.7 – Mapa com a georreferenciação das irregularidades da via.

A sensibilidade dos dois métodos é bem distinta, sendo que o sensor óptico é muito mais sensível que o acelerómetro (figura 4.1.7).

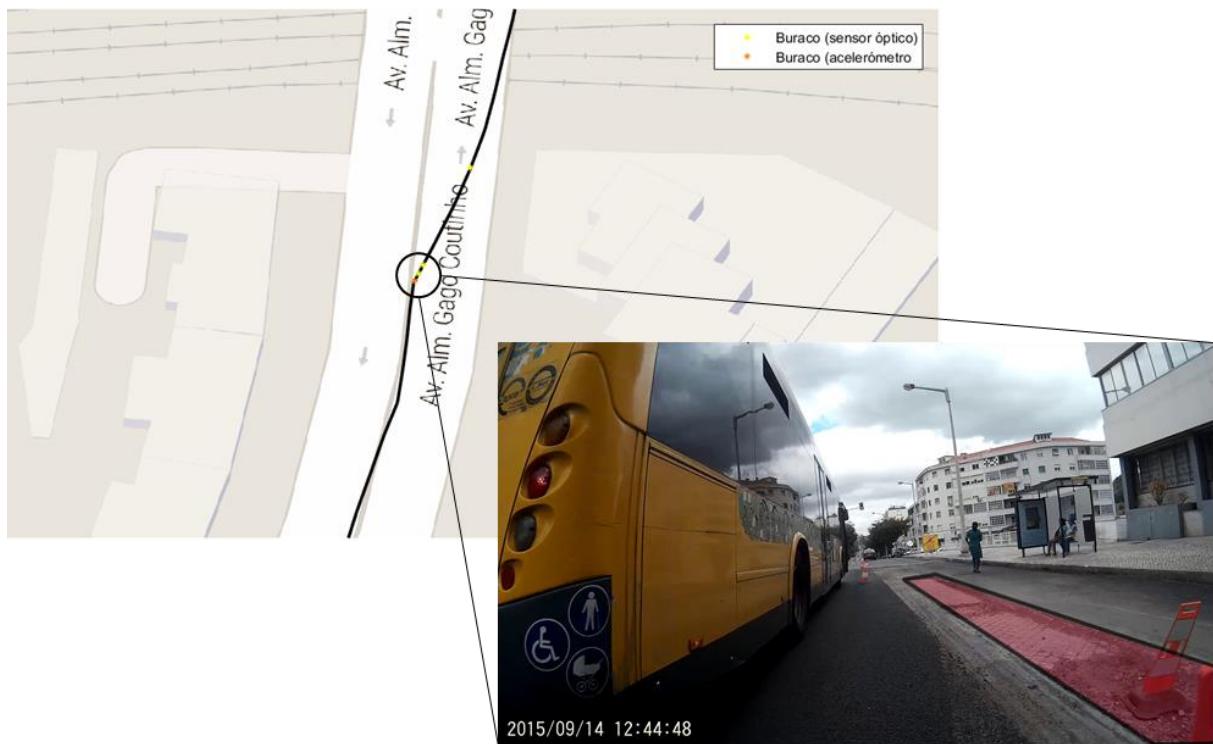


Figura 4.1.8 – Irregularidade na via detectada por ambos os métodos: desnível na estrada devido a remoção do alcatrão.

O acelerómetro apenas detecta grandes irregularidades na via (figura 4.1.8), enquanto que o sensor óptico é muito mais sensível, retornando por isso muitos falsos positivos, principalmente em caminhos empedrados (figura 4.1.9).

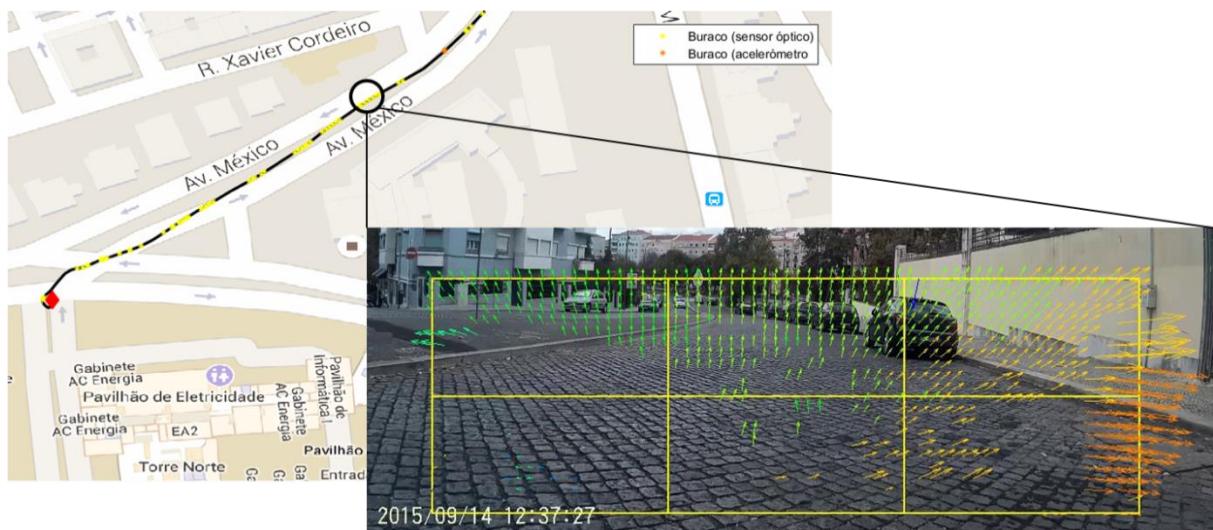


Figura 4.1.9 – Falso positivo do evento “irregularidade da via”, detectado pelo sensor óptico.

4.2 HRV - Variabilidade cardíaca

Com o método descrito no capítulo 3.3, foi possível determinar a distribuição geográfica do ratio LF/HF. Quanto maior este ratio, maior a dominância do sistema simpático sobre o parassimpático e consequentemente maior o estado de “stress” do ciclista.

Como a análise da variabilidade cardíaca é feita com base em intervalos de 2 min, temos de analisar o mapa com base nas “manchas” e não com base em pontos específicos. Na figura 4.2.1 podemos ver a distribuição geográfica do ratio LF/HF do percurso em análise.

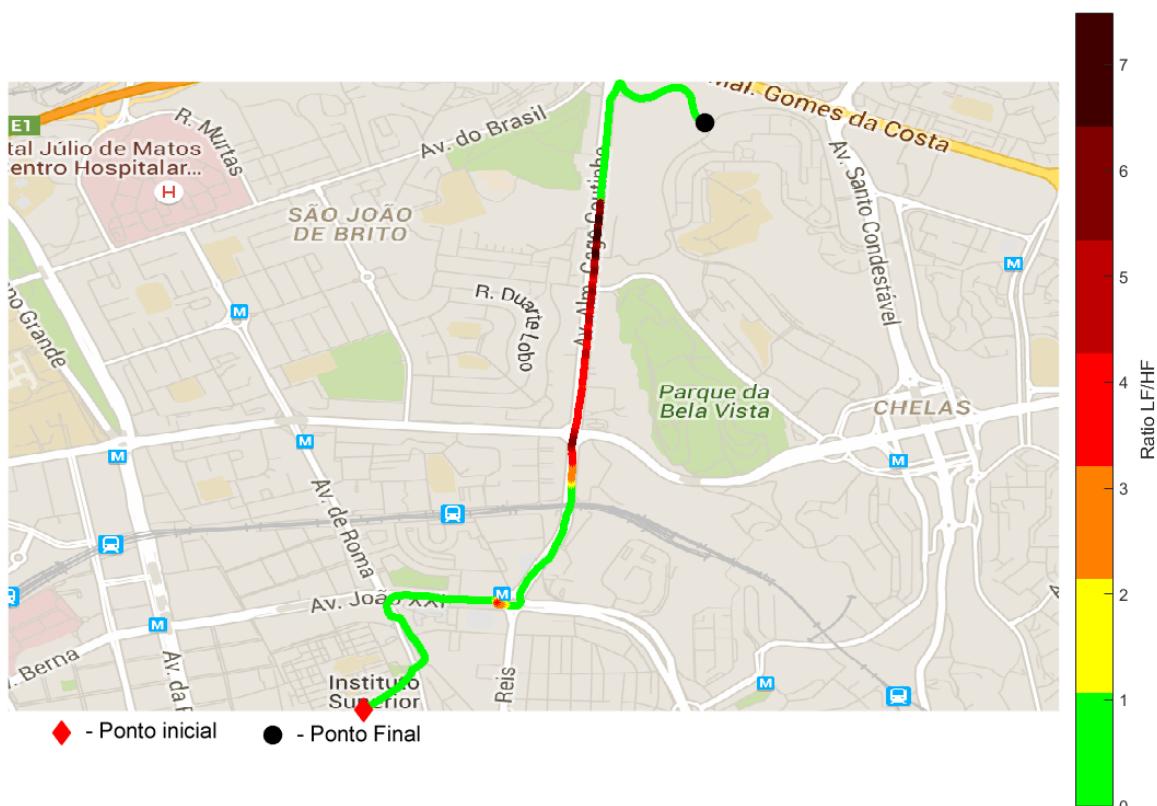


Figura 4.2.1 – Distribuição geográfica do ratio LF/HF.

No mapa ilustrado na figura 4.2.2, a zona A corresponde a uma subida, pelo que quando comparado com o mapa da velocidade (figura 4.1.1) verificamos que a velocidade é menor.

Tratando-se de uma subida sabemos que requer mais esforço do ciclista, o que influencia o ratio LF/HF do mesmo.

No entanto, na zona B, apesar de também corresponder a uma subida, o ratio LF/HF diminui. Isto acontece porque já se deu a estabilização do valor de VO₂. [20]



Figura 4.2.2 – Mapa do ratio LF/HF com subida assinalada.

É também possível verificar que existem duas zonas do mapa que apesar de não corresponderem a subidas, apresentam um alto ratio LF/HF (Figura 4.2.3).

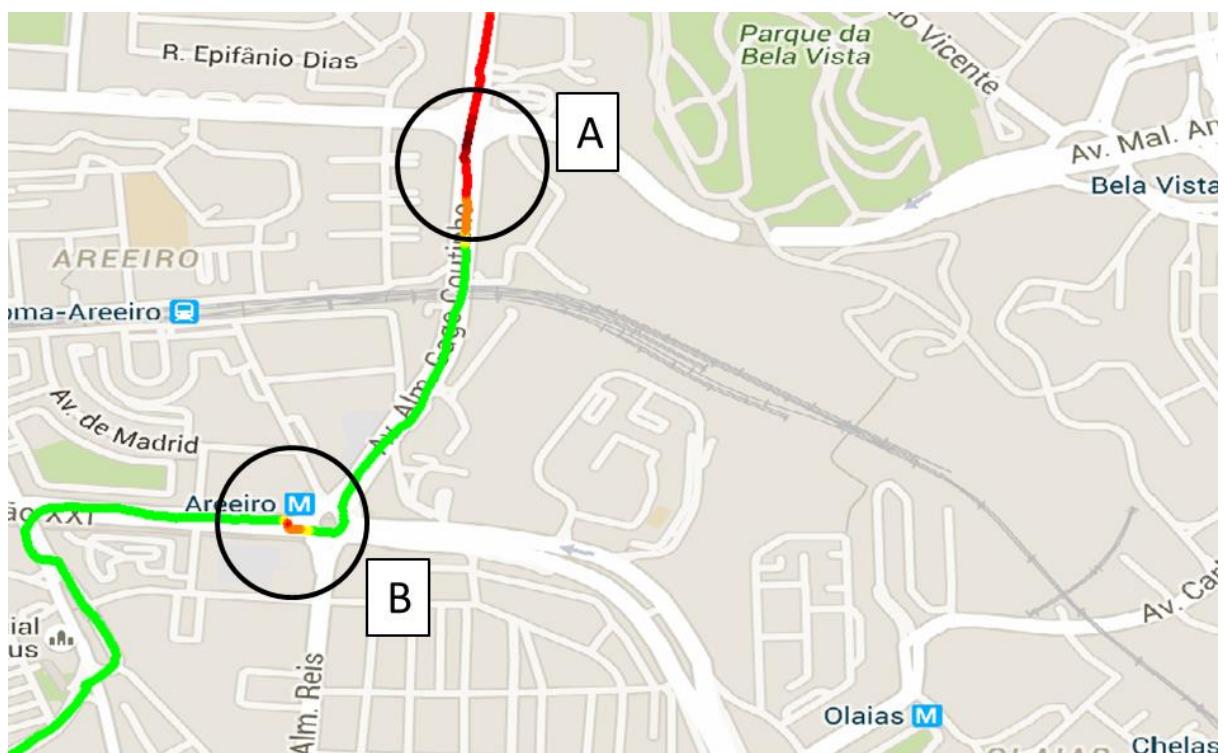


Figura 4.2.3 – Mapa do ratio LF/HF com zonas assinalados.

Ao analisar as imagens referentes à zona A, verificou-se que um automóvel ultrapassou o ciclista pela esquerda, muito próximo do mesmo (figura 4.2.4). Esta rasante ao ciclista poderá estar associada ao aumento da estimulação simpática registada.



Figura 4.2.4 – Ultrapassagem rasante ao ciclista pela esquerda.

Já na zona B, ao analisarmos as imagens, verificamos que a rotunda do Areeiro apresentava um alto tráfego nessa hora (figura 4.2.5), pelo que poderá ou não ter influenciado um aumento da estimulação do sistema simpático.

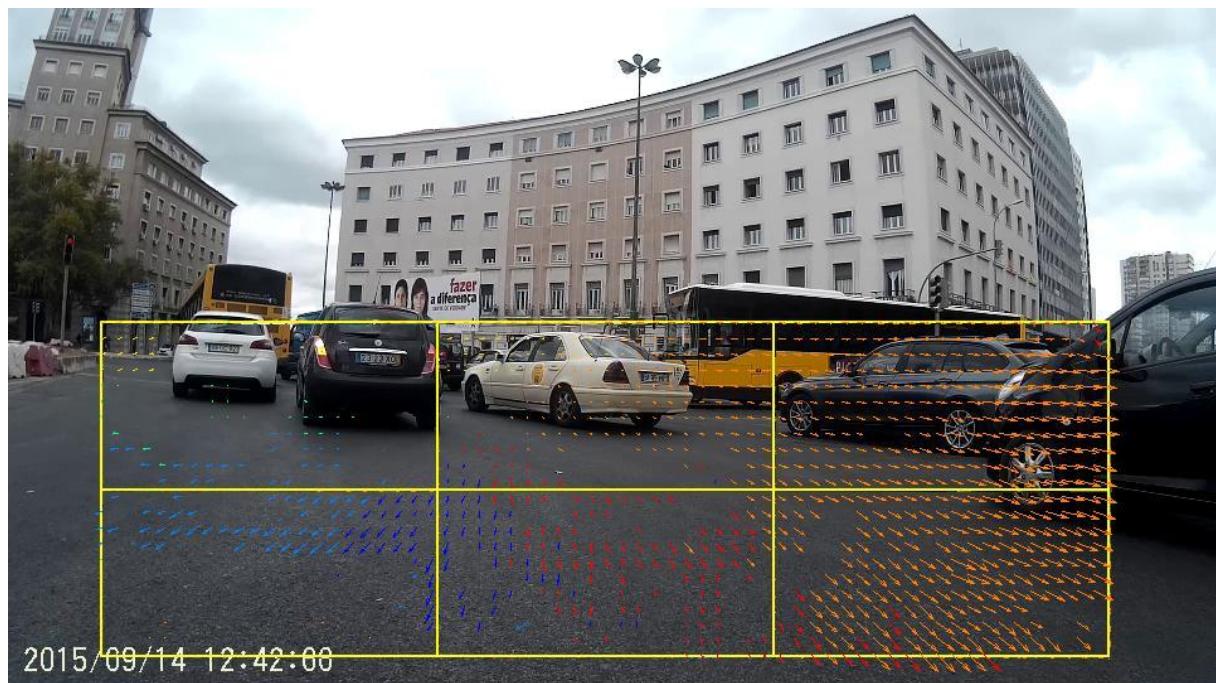


Figura 4.2.5 – Imagem da zona B - Rotunda do Areeiro.

Capítulo 5

Conclusões

Neste capítulo serão apresentadas as conclusões e trabalho futuro que poderá ser desenvolvido no seguimento desta tese.

5.1 Conclusões

Com este trabalho foi possível provar que os *smartphones*, aparelhos que abundam nos dias de hoje, podem ser usados como ferramentas de análise dos ciclistas em ambiente urbano. Tornam possível a identificação de situações que podem causar desconforto dos mesmos.

Também foi possível concluir que a análise do *flow* das imagens capturadas torna possível a extracção de diversos dados relevantes para a análise dos ciclistas nas cidades.

Ainda, em relação à análise da variabilidade cardíaca como identificador de *stress*, apesar de ser uma ferramenta poderosa e de fácil implementação, não é a mais indicada por ser afectada pelo esforço físico. Devem ser procuradas outras alternativas.

5.2 Trabalho futuro

Depois de se ter provado o conceito com esta dissertação, dever-se-á continuar o estudo dos ciclistas nas estradas das cidades.

Através da base de dados disponibilizada, propõe-se um estudo de possíveis alternativas ao classificador desenvolvido. Dever-se-ia estudar uma classificação baseada na análise de imagens anteriores e posteriores àquela que foi escolhida para objecto de estudo. De facto, os eventos não ocorrem isolados, sendo pertinente perceber o todo em que ocorrem, de forma a melhorar a performance do classificador. Bem como fazer uma classificação com base nos dados do GPS combinados com os dados ópticos.

Seria também de interesse disponibilizar e implementar a *App* desenvolvida num grande número de ciclistas, de modo a obter dados de uma amostra significativa. Com isto, seria possível melhorar futuramente as condições de circulação para os ciclistas, aumentando o seu conforto e a sua segurança.

Referências

- [1] “Europa: menos automóveis, mais bicicletas,” 2013. [Online]. Available: <http://p3.publico.pt/actualidade/ambiente/7649/europa-menos-automoveis-mais-bicicletas>. [Accessed: 29-Jan-2015].
- [2] S. C. José Levy, Paulo Jorge, Paulo Lourenço, Liliana Claro, “Cada vez mais pessoas utilizam bicicleta em Lisboa.” [Online]. Available: <http://www.rtp.pt/noticias/index.php?article=781330&tm=8&layout=122&visual=61>. [Accessed: 20-May-2001].
- [3] M. Winters, S. Babul, H. J. E. H. (Jack) Becker, J. R. Brubacher, M. Chipman, P. Cripton, M. D. Cusimano, S. M. Friedman, M. A. Harris, G. Hunte, M. Monro, C. C. O. Reynolds, H. Shen, and K. Teschke, “Safe Cycling: How Do Risk Perceptions Compare With Observed Risk?,” *Can J Public Heal.*, vol. 103, no. 9, pp. eS42–eS47, 2012.
- [4] M. C. Mekuria, P. G. Furth, and H. Nixon, “Low-Stress Bicycling and Network Connectivity,” p. 68, 2012.
- [5] T. B. H. T. R. Y. Brainwaves, “The Bike Helmet That Reads Your Brainwaves,” 2014. [Online]. Available: <http://spectrum.ieee.org/tech-talk/biomedical/devices/the-bike-helmet-that-reads-your-brainwaves>. [Accessed: 09-Feb-2014].
- [6] S. Candefjord, L. Sandsjö, R. Andersson, N. Carlborg, A. Szakal, J. Westlund, and M. West, “Using Smartphones to Monitor Cycling and Automatically Detect Accidents - Towards eCall Functionality for Cyclists,” no. November, 2014.
- [7] “Toronto Cycling App.” [Online]. Available: <http://www1.toronto.ca/wps/portal/contentonly?vgnextoid=5c555cb1e7506410VgnVCM10000071d60f89RCRD&vgnextchannel=6f65970aa08c1410VgnVCM10000071d60f89RCRD&appInstancename=default>. [Accessed: 19-Aug-1BC].
- [8] P. Ramos, “Projecto de Ciclovias,” 2008.
- [9] Niel F. Neimark, “The Fight or Flight Response,” *TheBodySoulConnection*, no. February 2010, p. 1.
- [10] F. P. de Souza, “Volume 3 - O estresse forte e o desgaste geral,” 1999. [Online]. Available: http://labs.icb.ufmg.br/lpf/revista/revista3/volume3_estresse_desgaste.htm. [Accessed: 09-Feb-2014].
- [11] H. R. V. European Society of Cardiology, and C. U. of Measurement, Physiological Interpretation, T. F. of T. E. S. of C. and T. N. American, and S. of P. and Electrophysiology, “Guidelines Heart rate variability,” *Eur. Heart J.*, vol. 17, pp. 354–381, 1996.
- [12] J. L. a. de Carvalho, a. F. da Rocha, F. a. de Oliveira Nascimento, J. S. Neto, and L. F. Junqueira, “Development of a Matlab software for analysis of heart rate variability,” *6th Int. Conf. Signal Process. 2002.*, vol. 2, no. August 2015, pp. 1488–1491, 2002.
- [13] B. Horn and B. Schunck, “Determining optical flow’: A retrospective,” *Artif. Intell.*, vol. 59, no. 1–2, pp. 81–87, 1993.
- [14] B. D. Lucas and T. Kanade, “An iterative image registration technique with an application to stereo vision,” *7th international joint conference on Artificial intelligence*, vol. 2. pp. 674–679,

1981.

- [15] J. Shi and C. Tomasi, "Good Features to Track," *IEEE Conf. Comput. Vis. Pattern Recognit.*, 1994.
- [16] A. L. Carneiro, T. Lopes, and A. L. Moreira, "Mecanismos de adaptação ao exercício físico," *Aula Teor. Prat.*, p. 24, 2002.
- [17] J. M. a. Roque, "Variabilidade da Frequência Cardíaca," *Fac. Ciências do Desporto e Educ. Física - Univ. Coimbra*, pp. 1–32, 2009.
- [18] G. Milicević, "Low to high frequency ratio of heart rate variability spectra fails to describe sympatho-vagal balance in cardiac patients.,," *Coll. Antropol.*, vol. 29, pp. 295–300, 2005.
- [19] M. M. Corrales, "Normal values of heart rate variability at rest in a young, healthy and active Mexican population," *Health (Irvine. Calif.)*., vol. 04, no. 07, pp. 377–385, 2012.
- [20] S. Sarmiento, J. M. García-Manso, J. M. Martín-González, D. Vaamonde, J. Calderón, and M. E. Da Silva-Grigoletto, "Heart rate variability during high-intensity exercise," *J. Syst. Sci. Complex.*, vol. 26, no. 1, pp. 104–116, 2013.
- [21] N. Pai, A. Pmr, D. Madi, B. Achappa, S. Pai, and B. Unnikrishnan, "Original article Evaluation of 1-minute Heart rate variability during deep breathing as a Prognostic indicator in patients with Acute myocardial infarction," vol. 3, no. 1, pp. 2103–2106, 2012.